让小模型做好高频决策

Strands Decider × Jev × GPT： 从公开基准，到支付流程中的真实表现

01

理解模型

为什么输出候选答案?
三种实现有何差异?

02

观察证据

公开基准 + 四个支付场景
速度、选择、实际执行

03

决定下一步

如何优化 Decider？
哪些任务交给哪类模型?

模型原理 → 公开基准 → 项目实测 → 差异解释 → 优化路径 · 2026.10.12

软件流程，需要大量小而明确的判断

选哪个队列？调用哪个工具？证据是否足够继续？

接收请求

客户消息 / 当前状态

选择路径

队列 / 工具 / 下一步

检查结果

是否完成 / 是否升级

这些判断的共同点

候选明确、频繁调用、结果被代码消费

决策模型的目标

用受约束的输出，降低判断开销

自然语言理解与路径选择交给模型；金额、权限与执行前提由代码核验。

决策模型：状态输入，类型化答案输出

把一个复杂流程拆成明确问题，再在应用代码中组合答案。

共享输入：业务状态 + 问题 + 候选或判断条件

Choice • 多选一

该交给哪个客服队列?

支付 / 退款 / 商户运营

Noul • 是 / 否

是否表达了退款诉求?

返回 P(true)

Score • 有序评分

这条请求有多紧急?

在定义好的等级上评分

输出类型受约束 ≠ 业务判断必然正确；概率与置信度需要结合业务数据验证。

三个模型，同一个候选动作任务

比较的是软件判断能力；本演示不测自由长文本生成质量。

Strands Decider

开源 2B · 自行部署
Qwen 主体 + LoRA
Pointer Head 对候选评分

本项目： EC2 L4 常驻

Jev / TypeSafe

托管 System One API
类型化答案与概率
官方强调 RLCD 校准训练

本项目：实际版本 1.13.0

GPT / Bedrock

通用生成式模型
根据候选条件生成 JSON
本项目仅输出 choice ID

GPT-6.1 Sol · 推理 low

Decider 与 Jev 的概率有助于观察选择偏向；不同模型的 confidence 不能直接视为同一种正确率。

Strands Decider： 用候选评分头完成选择

官方 v19： Qwen3.5-2B-Base + rank-16 LoRA + Pointer Head

输入业务

state / question

criteria / 候选

→

模型主体

Qwen3.5-2B

LoRA 任务适配

→

候选评分

Pointer Head

候选位置 ↔ 答案位置

→

输出决策

选择 / 分布

概率 / 置信信息

对当前候选直接评分，减少逐 token 文本生成

适合明确、聚焦的判断；开放式写作与复杂长链推理，需要不同模型能力。

相同业务问题，三条调用路径

应用提供事实、问题与候选条件；模型返回建议，执行器再检查。

Strands Decider	编码事实与候选	→ Pointer Head 评分	→ 选择 + 分布
Jev 1.13.0	提交业务事实、问题与候选项	→ 托管决策模型	→ 选择 + 分布
GPT-6.1 Sol	提示事实与候选	→ 生成候选 ID JSON	→ 解析与格式校验

输出受约束，只保证形状与候选范围；条件是否理解正确，需要业务评测。

BERT 、 Decider 、 GPT ： 适配方式一页看懂

区别在输出头、候选表达与任务范围。

BERT 分类器

固定标签 → 分类头
标签稳定、领域标注
新增类别通常需适配

Decider

请求候选 → 共享评分
条件用自然语言描述
专注有限动作选择

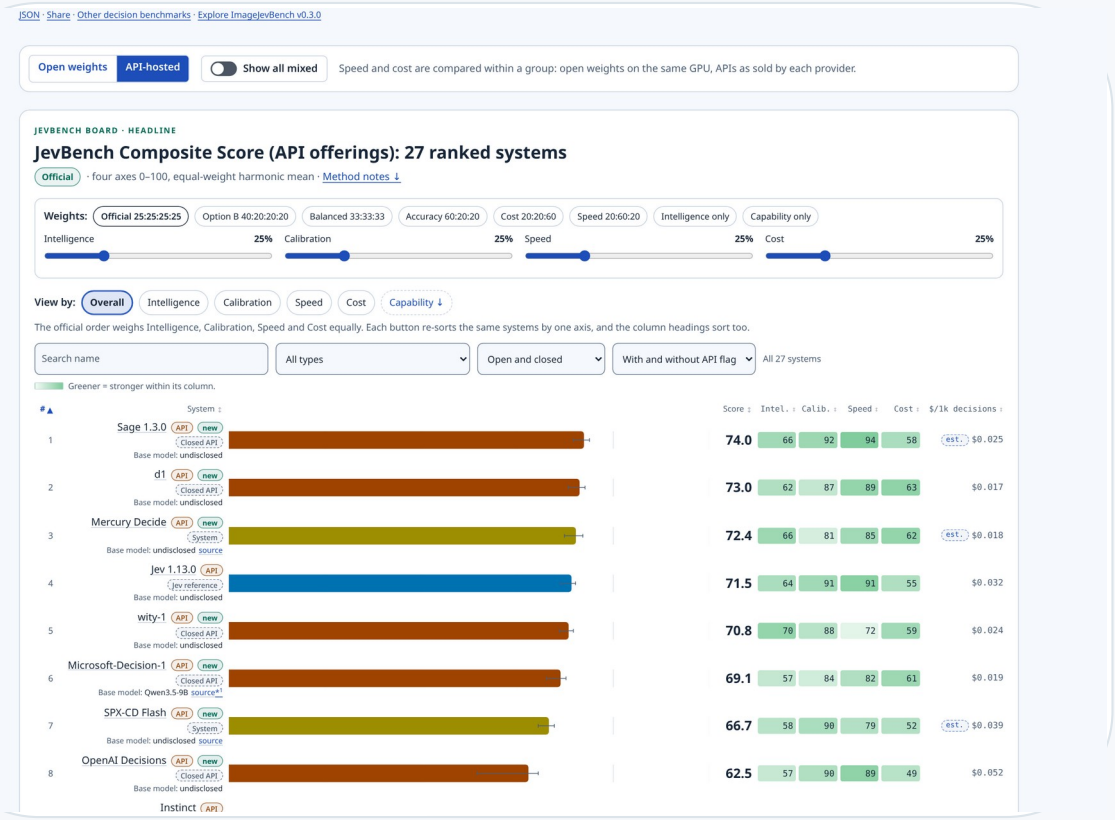
GPT

提示候选 → 生成 JSON
支持开放式生成与规划
也可做受限动作选择

BERT/NLI 也可做动态候选评分；本项目未对 BERT 进行速度或质量实测。

JevBench： 同时衡量能力、校准、速度与成本

Benchmark Heaven 第三方评测：综合分需要结合能力、速度与成本一起看。



[评测与方法：benchmarkheaven.com/jev-models/api](benchmarkheaven.com/jev-models/api)

综合分采用四轴等权调和平均，并对部分低于 50 的轴加惩罚；高综合分不等于最高答题能力。

Intelligence

类型化决策任务的能力分

Calibration

概率有多可信

Speed

测量或注明调整的响应耗时

Cost

标价建模成本；部分为估算

公开结果： Jev 与主流开源、闭源模型

能力、校准、综合分越高越好；延迟、成本越低越好。全部是该榜单配置。

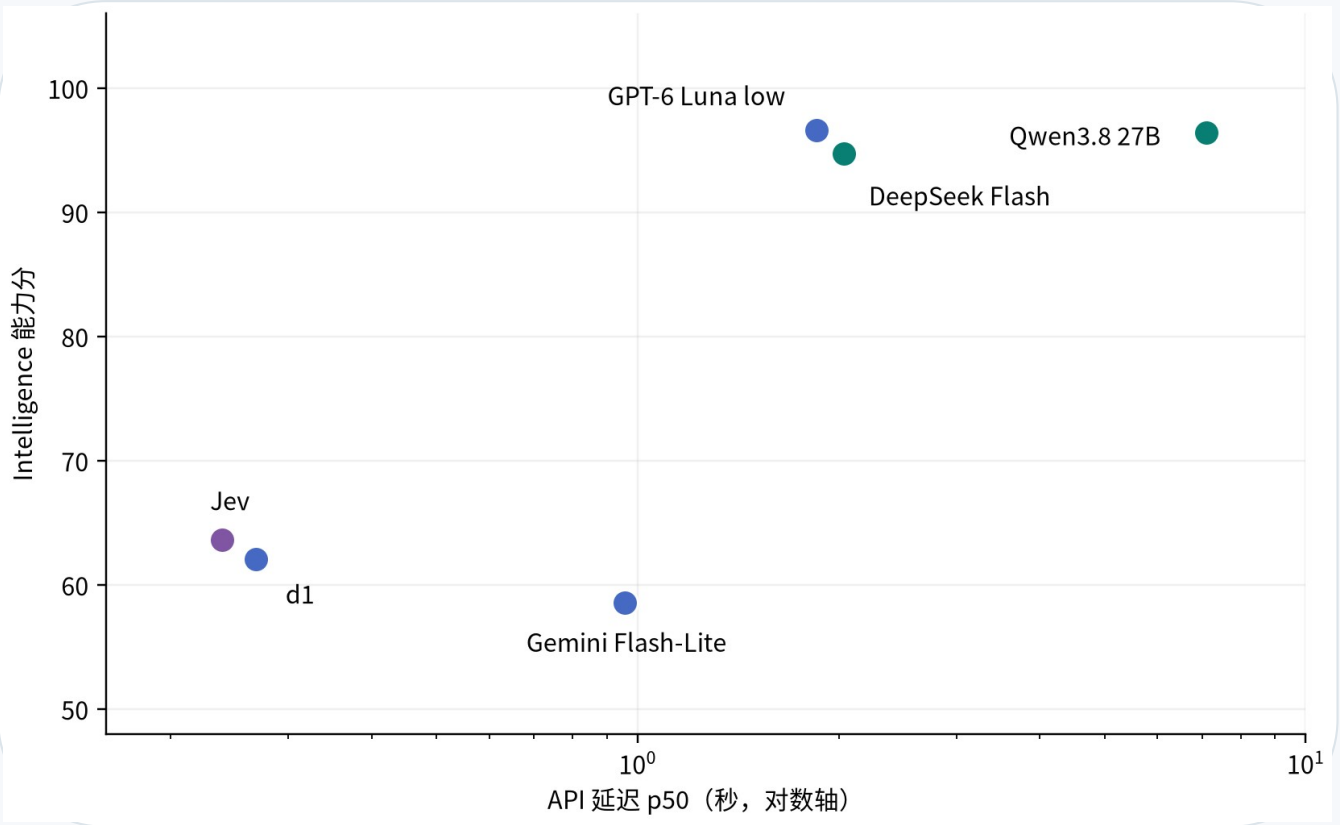
模型 / 配置	权重	综合	能力 I	校准 C	延迟 p50	$/ 千决策
Sage 1.3.0	闭源	74.0	65.6	91.6	0.152 s	$0.025*
Liquid d1	闭源	73.0	62.1	86.8	0.268 s	$0.017
Jev 1.13.0	闭源	71.5	63.6	90.6	0.239 s	$0.032
GPT-6 Luna · low	闭源	40.5	96.6	99.0	1.854 s	$0.108
GPT-5.6 Luna · low	闭源	21.4	94.1	94.9	1.588 s	$0.213
Gemini 3.1 Flash-Lite	闭源	16.9	58.6	60.9	0.957 s	$0.230
DeepSeek V4.1 Flash	开放权重	7.1	94.7	100.0	2.038 s	$0.480
Qwen3.8 27B	开放权重	0.0	96.4	100.0	7.095 s	$2.178*

评测来源：benchmarkheaven.com/jev-models/api

* 为榜单估算成本；分数不是准确率百分比。 GPT-6.1 Sol 、 Claude 与 Strands v19 未列入此 API 表。

综合排名高，不等于复杂问题答得更准

Jev 的优势来自低延迟和低成本；强通用模型在该基准的能力分更高。



先按任务选能力

榜单中 GPT / DeepSeek / Qwen 能力分高，但速度与成本不同。

Decider 的另一份证据

官方公开子集： 167 / 231

准确率 72.29%

不可与本页归一化分数混排。

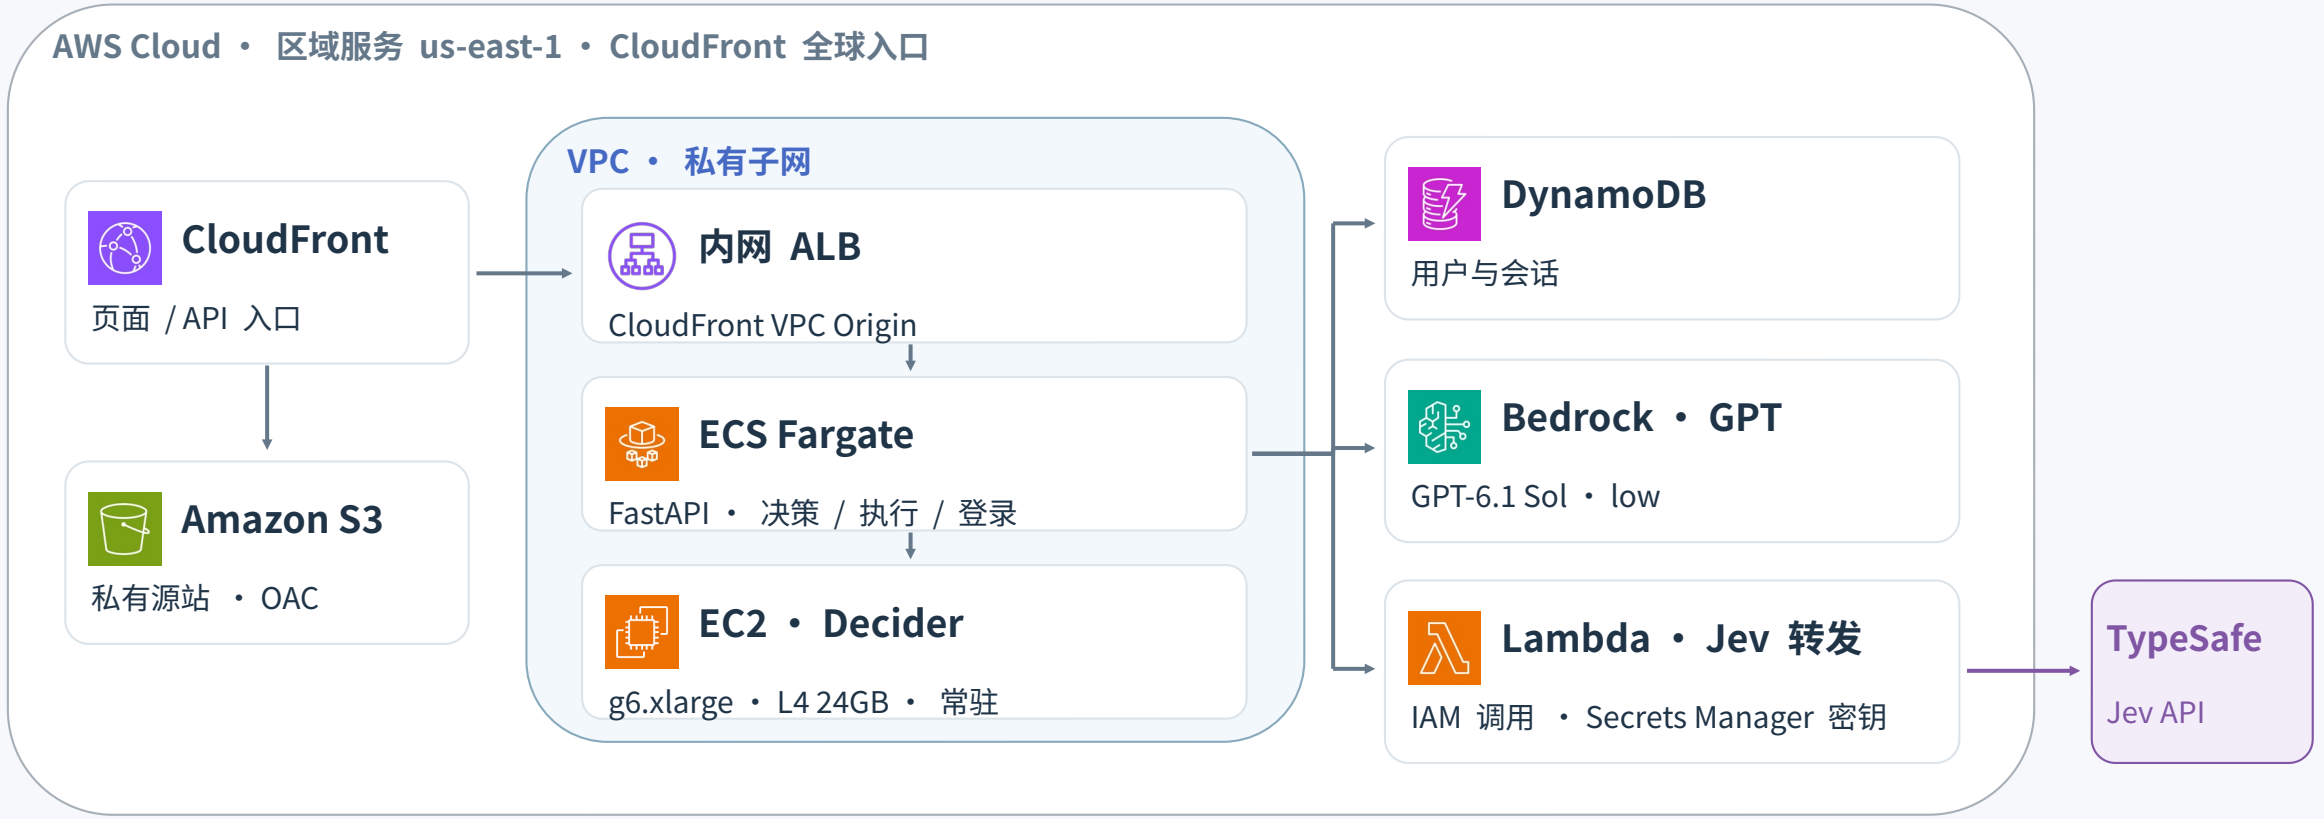
评测：benchmarkheaven.com/jev-models/api

Decider 来源：官方 v19 模型卡

公开基准用于筛选候选模型；是否适合你的支付策略，需要在真实业务输入上重新验证。

一套业务后端，连接三个模型

us-east-1 · 私有 S3 + CloudFront OAC · ECS Fargate · EC2 g6.xlarge / L4



自建用户名登录；业务后端统一校验候选和执行条件。图省略网络端点与非主路径的运维组件。

四个支付场景，贯穿五个业务节点

同一笔业务，分别交给 Decider 、 Jev 和 GPT 。

未到账

确认数 3 / 12

少付

100 → 99.80

退款

地址与审批待补齐

结算

到账状态与时效

客服受理

节点 1

→

交易核验

节点 2

→

风控审批

节点 3

→

业务处置

节点 4

→

回复结案

节点 5

客户消息、事实快照与候选条件均可追溯。

真实界面：同一输入，三模型输出并排看

相同事实、问题和候选条件；保留各自的原始选择、耗时与实际执行。



先看原始选择，再看实际动作；模型给出建议，业务系统负责执行。

四场景总览： Decider 最快，两处选择仍有差异

每格：该场景五步累计后端耗时 · 与演示参考一致次数

业务场景	Strands Decider	Jev 1.13.0	GPT-6.1 Sol
USDC 未到账	0.557 s · 5/5	2.318 s · 5/5	8.537 s · 5/5
USDT 少付	0.514 s · 4/5	1.896 s · 5/5	4.171 s · 5/5
稳定币退款	0.564 s · 4/5	2.112 s · 5/5	5.453 s · 5/5
商户结算	0.408 s · 5/5	2.003 s · 5/5	4.173 s · 5/5
20 步合计	2.043 s · 18/20	8.329 s · 20/20	22.335 s · 20/20

102.2 ms
平均每次后端耗时

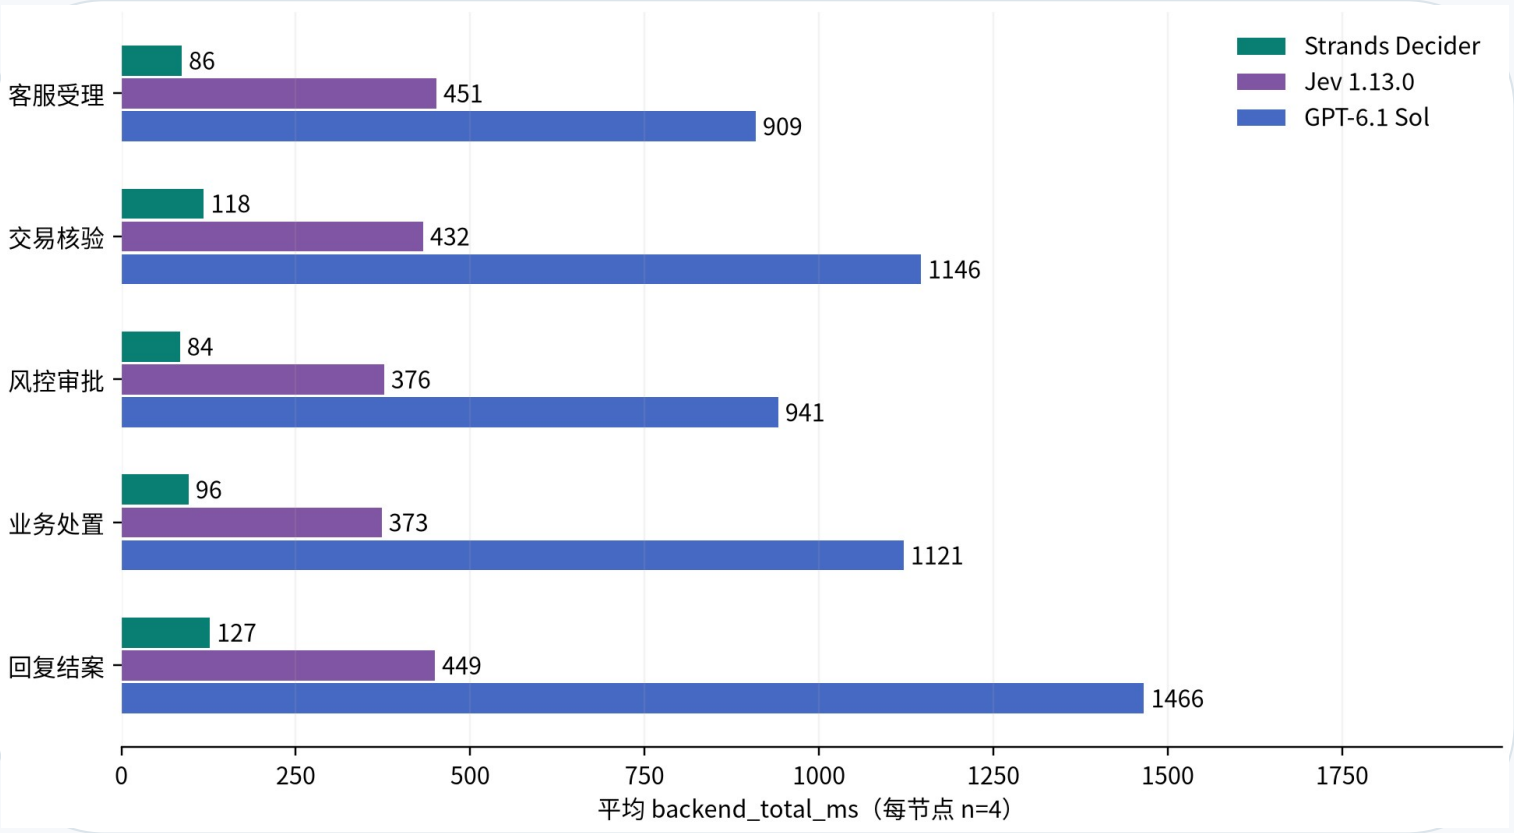
416.5 ms
平均每次后端耗时

1116.7 ms
平均每次后端耗时

预热后： Jev / Decider = 4.08×； GPT / Decider = 10.93×； GPT / Jev = 2.68× 。耗时含通信与后端处理。

逐节点看速度：受理、核验、审批、处置、回复

左侧比较各节点平均耗时；右侧查看每个模型的请求中位数。



Strands Decider

81.3 ms

Jev 1.13.0

397.7 ms

GPT-6.1 Sol

863.4 ms

右侧： 20 次请求中位数

每节点各 4 次；每模型共 20 次。比较的是应用调用耗时，不能当作模型纯计算时间。

USDC 未到账：三模型都等待确认

129 USDC 已足额；确认 3/12 。审批可通过，资金仍不能入账。

业务节点	Strands Decider	Jev	GPT
客服受理	支付客服 • 109 ms	支付客服 • 550 ms	支付客服 • 1108 ms
交易核验	等待链上确认 • 137 ms	等待链上确认 • 514 ms	等待链上确认 • 885 ms
风控审批	规则检查通过 • 76 ms	规则检查通过 • 364 ms	规则检查通过 • 1176 ms
业务处置	挂起并跟进 • 155 ms	挂起并跟进 • 461 ms	挂起并跟进 • 2084 ms
回复结案	回复并持续跟进 • 81 ms	回复并持续跟进 • 429 ms	回复并持续跟进 • 3284 ms



一致的判断：等待确认 → 检查通过 → 挂起并跟进。

USDT 少付：确认已够，仍需补款

应付 100 ，到账 99.80 USDT ；确认 20/12 。差额 0.20 才是当前阻塞。

业务节点	Strands Decider	Jev	GPT
客服受理	支付客服 • 82 ms	支付客服 • 439 ms	支付客服 • 873 ms
交易核验	等待链上确认 • 110 ms	请求补足差额 • 394 ms	请求补足差额 • 820 ms
风控审批	规则检查通过 • 105 ms	规则检查通过 • 365 ms	规则检查通过 • 855 ms
业务处置	挂起并跟进 • 79 ms	挂起并跟进 • 322 ms	挂起并跟进 • 798 ms
回复结案	回复并持续跟进 • 138 ms	回复并持续跟进 • 376 ms	回复并持续跟进 • 825 ms



关键差异： Decider 等待确认； Jev / GPT 要求补款。

退款审批：原始建议与实际采用动作不同

250 USDC 退款；资金已核验，但地址未验证、人工审批未通过。

业务节点	Strands Decider	Jev	GPT
客服受理	退款专员 • 79 ms	退款专员 • 350 ms	退款专员 • 824 ms
交易核验	到账已核验 • 148 ms	到账已核验 • 348 ms	到账已核验 • 2006 ms
风控审批	规则检查通过 • 79 ms	验证退款地址 • 437 ms	验证退款地址 • 932 ms
业务处置	挂起并跟进 • 75 ms	挂起并跟进 • 385 ms	挂起并跟进 • 777 ms
回复结案	回复并持续跟进 • 183 ms	回复并持续跟进 • 591 ms	回复并持续跟进 • 914 ms



执行保护： Decider 「检查通过」→「验证地址」；三侧均挂起退款。

商户结算：先升级工单，再等待到账

4,800 USDC； 120 分钟未到账，演示 SLA 为 60 分钟。

业务节点	Strands Decider	Jev	GPT
客服受理	商户运营 • 75 ms	商户运营 • 466 ms	商户运营 • 831 ms
交易核验	结算超时 • 77 ms	结算超时 • 473 ms	结算超时 • 872 ms
风控审批	规则检查通过 • 75 ms	规则检查通过 • 339 ms	规则检查通过 • 802 ms
业务处置	升级结算工单 • 76 ms	升级结算工单 • 324 ms	升级结算工单 • 827 ms
回复结案	回复并持续跟进 • 105 ms	回复并持续跟进 • 402 ms	回复并持续跟进 • 841 ms



一致的判断：识别超时 → 升级结算工单 → 持续跟进；尚未对账结案。

为什么选择不同？先分清观察与解释

自然语言候选条件由模型近似判断；同一输入不保证同一选择。

已观察到

少付：确认已达标，仍等待
退款：条件不足，过早通过

Jev / GPT 本次符合参考
Decider 两处与参考不同

合理解释，待验证

条件组合与适用范围
训练分布和语言表达
候选评分与生成机制

不能把输出当内部思维链

概率不能代替检查

少付误选 confidence 0.814
退款误选 confidence 0.252

高置信也会错
需要业务校准与执行保护

GPT / Jev 的 20/20 是本批次参考一致； Decider 的概率分布是偏向证据，不是业务正确性的证明。

五步已处理，为什么三个模型都没有结案?

初始四场景都有未补齐的外部条件；固定输入运行不会自动改变证据。

模型返回

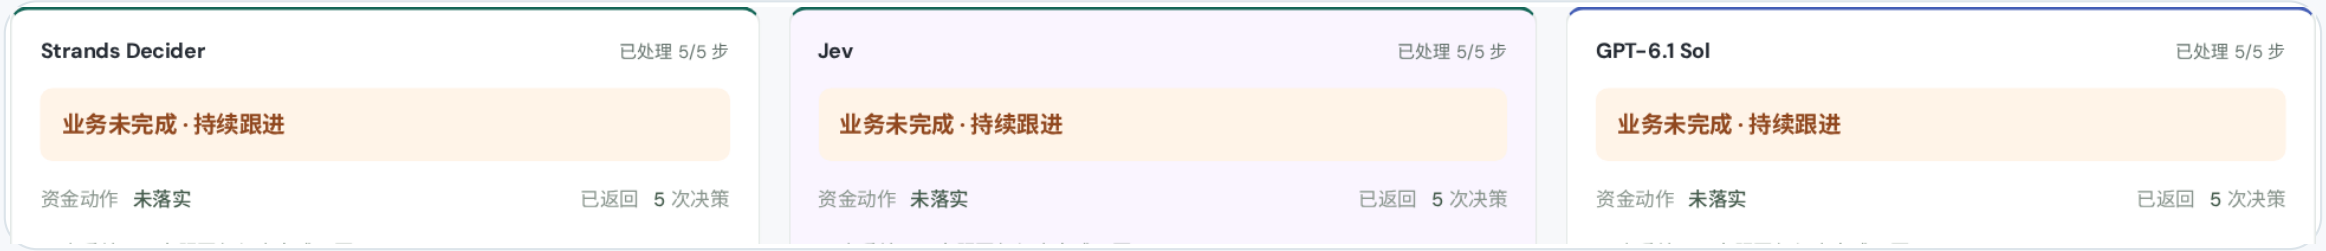
三个模型各 20/20 次成功

步骤处理

四场景均已处理 5/5 步

业务完成

初始证据下各 0/4 完成



仍缺什么? 未到账：确认达标 • 少付：补足差额 • 退款：地址与审批 • 结算：到账证据

完成标准：目标订单状态 + 对应模拟账本 + 工单结案。模型调用成功、选择正确、业务完成是三件事。

Jev 为什么没有宣传中的几十倍加速?

本批次 GPT / Jev = 2.68×；比较条件决定加速倍数。

Decider

ECS → 私网 EC2
本地部署的候选评分

Jev

ECS → Lambda → HTTPS
包含代理与外部往返

GPT

ECS → Bedrock
low 推理，只输出 ID

同一 Jev，两个观察位置	响应中位数	正确解读
JevBench API 公开结果	239.1 ms	第三方任务与测量网络
本项目支付 20 次调用	397.7 ms	含 Lambda、HTTPS 与后端处理

即使预热，网络往返与代理处理仍占用时间； GPT 只输出候选 ID，也会缩小速度差距。

闭环做了什么：等待证据、重新核验、完成入账

USDC 案例 · 三侧各 6 次决策 +1 次模拟确认事件，最终都完成。

实际检查

确认不足 → 暂停资金

模拟器事件

确认数 3/12 → 12/12

携带反馈重判

重新核验 → 入账 → 结案



三侧实际结果：订单已收款 · 模拟账本 129 USDC · 工单已结案

Decider 首轮误选「结算已核验」，执行检查仍等待确认；后续重判完成。完成闭环不代表每次选择都正确。

优化示例：让退款审批只作用于退款

已验证的前后对照 · USDC 收款 · 只调整输入字段与候选条件

真实界面入口

测试方式 优化流程

精简字段 → 明确适用场景 → 重新判断

固定流程

收款事实 + refund_approved=false
退款字段仍出现在普通收款输入中

Decider： 等待人工审批 75.7 ms

GPT： 规则检查通过 1,080.1 ms

优化流程

收款事实，移除无关退款字段
候选明确：非退款不要求退款审批

Decider： 规则检查通过 80.2 ms

GPT： 规则检查通过 820.3 ms

本次优化改变输入与条件表述；候选 ID 、模型权重和执行校验保持一致。

确认数仍为 3/12： 两侧资金继续挂起。审批选择改善，不表示已经到账。

已验证的优化： Decider 参考一致 14/20 → 18/20

明确候选适用范围、去除无关字段，减少两类业务条件之间的混淆。

业务场景	Decider 固定	Decider 优化
USDC 未到账	4/5	5/5
USDT 少付	4/5	4/5
稳定币退款	2/5	4/5
商户结算	4/5	5/5
合计	14/20	18/20

已验证的变化

参考一致改善；保护调整 4 → 1

模型权重未变，未进行领域微调。

当前三模型再次观察

Decider 18/20 · Jev / GPT 20/20

剩余：少付核验、退款审批

仍需下一轮优化与独立测试。

优化输入已减少选择错误；模型权重未变。少付核验与退款审批仍需改进。

下一步优化：把剩余错误变成可重复的测试

优先改问题表达与任务拆分，再判断是否需要改模型权重。

收集错误

事实 + 候选 + 原始选择

实际执行 + 人工正确动作

→

构造最小对照

只改一个条件或边界

加入近似反例与语言变体

→

验证改动

冻结测试集与版本

比较错误、延迟和完成率

少付：把确认与金额分开

确认达到阈值后，明确跳过等待确认；

用差额 0 / 0.01 / 0.20 测补款分支。

退款：先限定场景，再检查前提

地址验证 → 人工审批 → 执行资格；

覆盖缺失、冲突、风险优先等反例。

这是后续实验方案，未宣称已提升效果；参考与真实执行保护必须独立于模型输出。

需要微调时：训练决策能力，不只训练 JSON 外形

沿用官方训练链路，适配 LoRA 与 Pointer Head；先准备独立领域评测。

领域样本

真实案件去标识

覆盖正常与困难反例

→

人工标注

正确候选 / 判断依据

教师模型只辅助

→

参数适配

LoRA + 候选评分头

沿用类型化决策目标

→

独立评测

保留集 + 校准 + 延迟

灰度验证与可回滚

必须守住的边界	目的
按案件、模板簇、时间切分	避免同义样本跨训练与测试集泄漏
保留通用任务与所有问题类型的回归集	防止领域改善伴随能力退化
执行保护独立；上线前核验实际业务结果	不把微调后的高置信选择直接当资金授权

当前演示没有修改模型权重；本页是下一阶段实施方法，尚无微调后的成绩或成本承诺。

落地方式：常见判断用小模型，复杂异常升级

先按业务效果建立分流，再用真实用量评估总体成本。

业务请求

消息 + 经过核验的事实

任务分流

明确、常见 → 小模型

复杂、冲突 → GPT / 人工

执行系统

检查条件、权限与账本

记录结果，反馈再判断

质量

按场景错误率

高风险误放行

校准与自动化覆盖率

性能

同任务重复测量

p50 / p95 / p99

吞吐、失败与超时

业务与成本

实际完成率与人工介入

常驻 GPU 利用率

托管用量与基础设施

置信度阈值应在独立业务集上校准；高置信也可能出错，执行保护始终独立。

总结：同时看速度、选择和真实业务结果

公开基准帮助选型；项目实测解释行为；独立评测验证优化。

模型	当前观察	适合继续验证的方向
Strands Decider	102.2 ms / 次 · 18/20	可自行部署的高频有限判断
Jev 1.13.0	416.5 ms / 次 · 20/20	托管决策、概率与接入成本
GPT-6.1 Sol	1116.7 ms / 次 · 20/20	复杂语义、异常处理和开放式生成

已验证：输入优化改善选择

待验证：领域微调与生产收益

本批次 20 个不同任务，不代表通用准确率或稳定延迟；四个初始场景均需外部条件才能完成资金业务。

打开 Demo，查看三模型过程与原始记录

从相同业务输入开始，核对每一步的建议、实际动作、耗时与最终结果。

在线 Demo

加密支付业务台 · 使用现有账号登录

https://d3i7ogfx5ml7dc.cloudfront.net/#crypto

GitHub Repo

公开仓库 · 架构、代码、资料与实测记录

https://github.com/milan9527/StrandsDecider

公开基准 benchmarkheaven.com/jev-models/api

原理来源： Strands 官方博客、官方模型卡、 TypeSafe System One； 完整链接与测量口径见逐页讲稿。