让小模型做好高频决策

Strands Decider × Jev × GPT： 支付、模型路由、并发性能与部署成本

01

理解模型

为什么输出候选答案?
三种实现有何差异?

02

观察证据

公开基准 + 四个支付场景
速度、选择、实际执行

03

决定下一步

如何优化 Decider ?
哪些任务交给哪类模型?

模型原理 → 业务决策 → 模型路由 → vLLM 性能 → 成本与选型 · 2026.10.13

软件流程，需要大量小而明确的判断

选哪个队列？调用哪个工具？证据是否足够继续？

接收请求

客户消息 / 当前状态

选择路径

队列 / 工具 / 下一步

检查结果

是否完成 / 是否升级

这些判断的共同点

候选明确、频繁调用、结果被代码消费

决策模型的目标

用受约束的输出，降低判断开销

自然语言理解与路径选择交给模型；金额、权限与执行前提由代码核验。

决策模型：状态输入，类型化答案输出

把一个复杂流程拆成明确问题，再在应用代码中组合答案。

共享输入：业务状态 + 问题 + 候选或判断条件

Choice • 多选一

该交给哪个客服队列?

支付 / 退款 / 商户运营

Noul • 是 / 否

是否表达了退款诉求?

返回 P(true)

Score • 有序评分

这条请求有多紧急?

在定义好的等级上评分

输出类型受约束 ≠ 业务判断必然正确；概率与置信度需要结合业务数据验证。

三个模型，同一个候选动作任务

比较的是软件判断能力；本演示不测自由长文本生成质量。

Strands Decider

开源 2B · 自行部署
Qwen 主体 + LoRA
Pointer Head 对候选评分

本项目： EC2 L4 常驻

Jev / TypeSafe

托管 System One API
类型化答案与概率
官方强调 RLCD 校准训练

本项目：实际版本 1.13.0

GPT / Bedrock

通用生成式模型
根据候选条件生成 JSON
本项目仅输出 choice ID

GPT-6.1 Sol · 推理 low

Decider 与 Jev 的概率有助于观察选择偏向；不同模型的 confidence 不能直接视为同一种正确率。

Strands Decider： 用候选评分头完成选择

官方 v19： Qwen3.5-2B-Base + rank-16 LoRA + Pointer Head

输入业务

state / question

criteria / 候选

→

模型主体

Qwen3.5-2B

LoRA 任务适配

→

候选评分

Pointer Head

候选位置 ↔ 答案位置

→

输出决策

选择 / 分布

概率 / 置信信息

对当前候选直接评分，减少逐 token 文本生成

适合明确、聚焦的判断；开放式写作与复杂长链推理，需要不同模型能力。

相同业务问题，三条调用路径

应用提供事实、问题与候选条件；模型返回建议，执行器再检查。

Strands Decider	编码事实与候选	→ Pointer Head 评分	→ 选择 + 分布
Jev 1.13.0	提交业务事实、问题与候选项	→ 托管决策模型	→ 选择 + 分布
GPT-6.1 Sol	提示事实与候选	→ 生成候选 ID JSON	→ 解析与格式校验

输出受约束，只保证形状与候选范围；条件是否理解正确，需要业务评测。

BERT 、 Decider 、 GPT： 适配方式一页看懂

区别在输出头、候选表达与任务范围。

BERT 分类器

固定标签 → 分类头
标签稳定、领域标注
新增类别通常需适配

Decider

请求候选 → 共享评分
条件用自然语言描述
专注有限动作选择

GPT

提示候选 → 生成 JSON
支持开放式生成与规划
也可做受限动作选择

BERT/NLI 也可做动态候选评分；本项目未对 BERT 进行速度或质量实测。

决策模型适用场景：把高频判断接入软件流程

在明确候选中选择、判断陈述支持程度、输出等级；业务系统消费结构化结果。

客服与运营

工单队列、升级路径、跟进等级

choice / score

支付与风控

等待确认、补款、地址核验

choice；执行系统保留资金校验

工具与模型路由

选处理流程、工具或目标型号

choice；需要候选能力事实

RAG 与质量检查

依据是否充分、是否继续检索

noul / choice

内容审核

内容类别、风险等级、人工升级

choice / score

告警与销售线索

业务影响分级、线索跟进优先级

score / choice

工作台提供相关示例；以下正式实测聚焦支付流程与模型路由，不宣称六类任务已全部验证。

适用条件：候选清晰、事实可得、结果可验证

先确认问题适合有限判断，再以独立业务样本验收质量、延迟和自动化覆盖率。

明确问题

选项有清楚语义

例：补款 / 等确认 / 人工

→

提供事实

已知状态 + 候选能力

缺失证据不能凭空补齐

→

模型建议

结构化选择与分数

阈值需单独校准

→

执行与反馈

条件 / 权限校验后执行

结果回传，必要时重判

适合优先试点

重复高频判断、边界明确、可留痕并验证结果

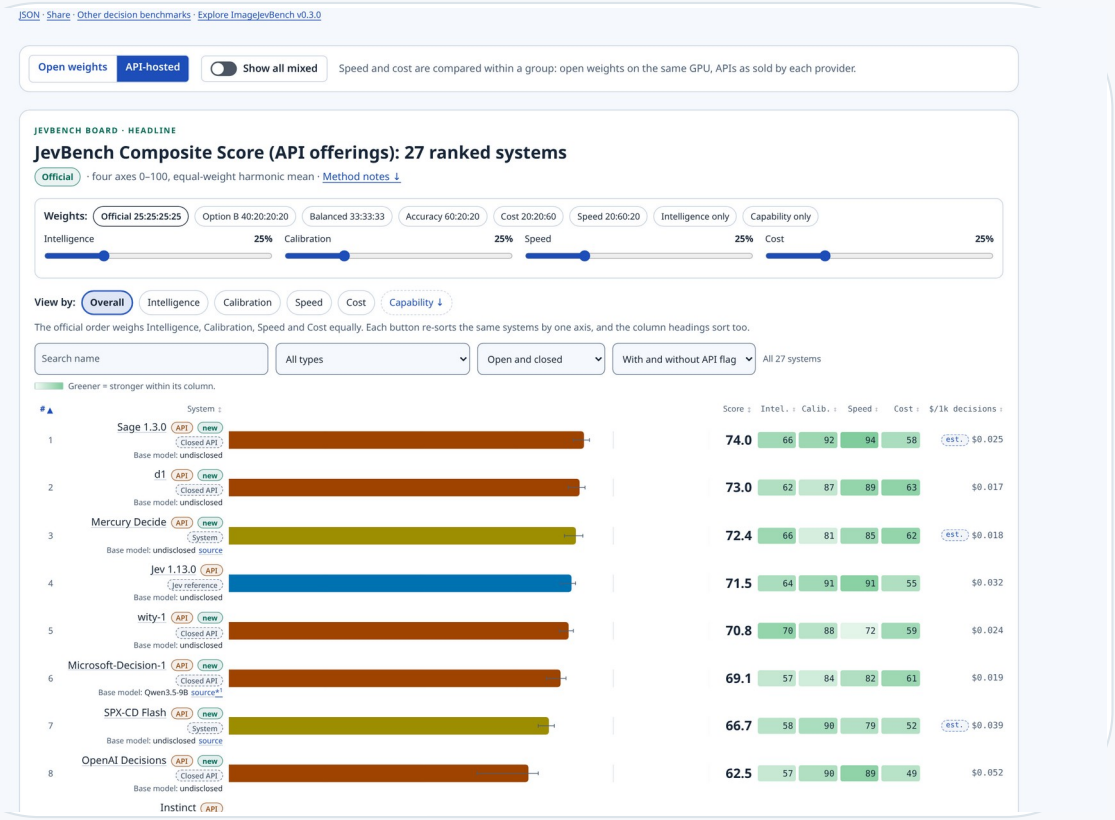
需要其他能力配合

长文本与代码生成交给生成模型；复杂异常可人工复核

类型合法不等于语义正确；金额计算、账本更新、权限和交易执行仍由业务系统负责。

JevBench： 同时衡量能力、校准、速度与成本

Benchmark Heaven 第三方评测：综合分需要结合能力、速度与成本一起看。



[评测与方法：benchmarkheaven.com/jev-models/api](benchmarkheaven.com/jev-models/api)

综合分采用四轴等权调和平均，并对部分低于 50 的轴加惩罚；高综合分不等于最高答题能力。

Intelligence

类型化决策任务的能力分

Calibration

概率有多可信

Speed

测量或注明调整的响应耗时

Cost

标价建模成本；部分为估算

公开结果： Jev 与主流开源、闭源模型

能力、校准、综合分越高越好；延迟、成本越低越好。全部是该榜单配置。

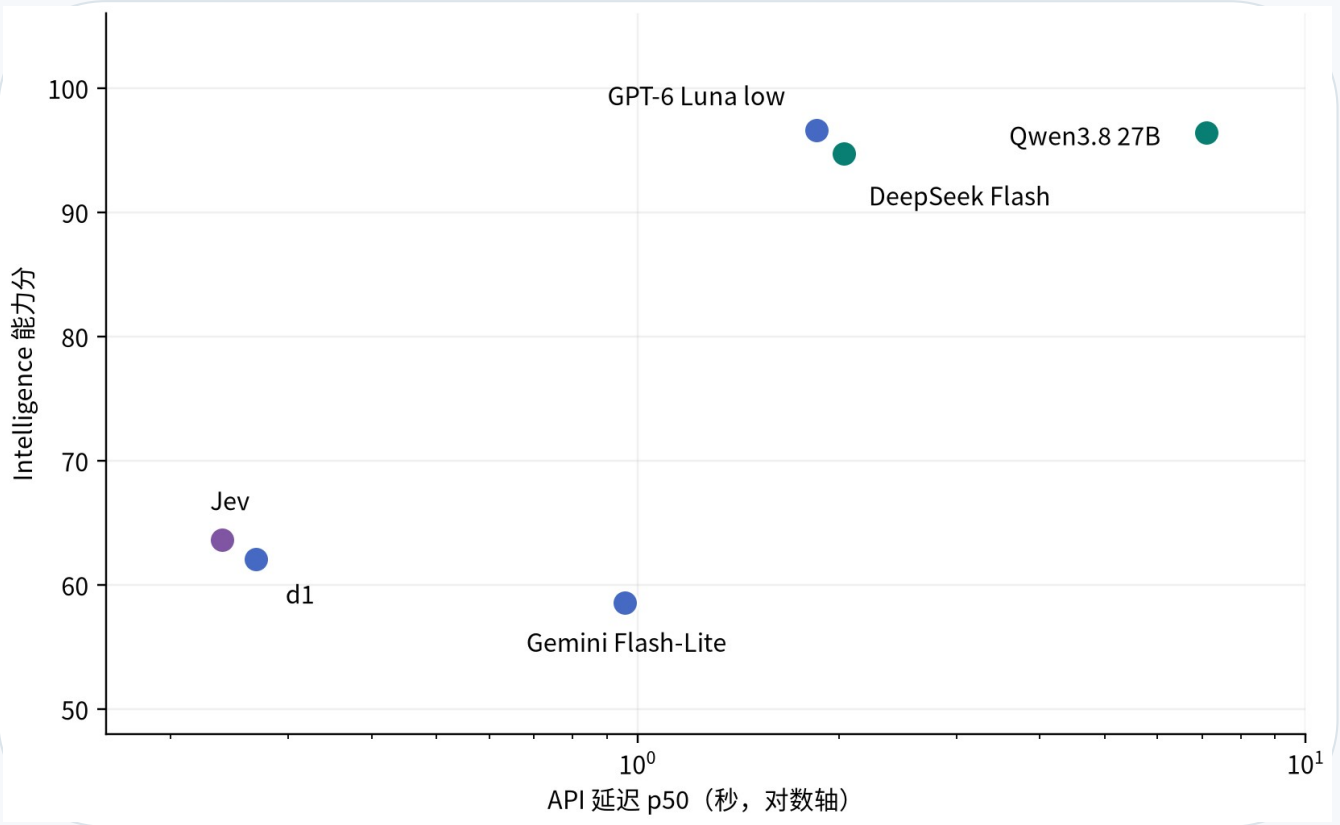
模型 / 配置	权重	综合	能力 I	校准 C	延迟 p50	$/ 千决策
Sage 1.3.0	闭源	74.0	65.6	91.6	0.152 s	$0.025*
Liquid d1	闭源	73.0	62.1	86.8	0.268 s	$0.017
Jev 1.13.0	闭源	71.5	63.6	90.6	0.239 s	$0.032
GPT-6 Luna · low	闭源	40.5	96.6	99.0	1.854 s	$0.108
GPT-5.6 Luna · low	闭源	21.4	94.1	94.9	1.588 s	$0.213
Gemini 3.1 Flash-Lite	闭源	16.9	58.6	60.9	0.957 s	$0.230
DeepSeek V4.1 Flash	开放权重	7.1	94.7	100.0	2.038 s	$0.480
Qwen3.8 27B	开放权重	0.0	96.4	100.0	7.095 s	$2.178*

评测来源：benchmarkheaven.com/jev-models/api

* 为榜单估算成本；分数不是准确率百分比。 GPT-6.1 Sol 、 Claude 与 Strands v19 未列入此 API 表。

综合排名高，不等于复杂问题答得更准

Jev 的优势来自低延迟和低成本；强通用模型在该基准的能力分更高。



先按任务选能力

榜单中 GPT / DeepSeek / Qwen 能力分高，但速度与成本不同。

Decider 的另一份证据

官方公开子集： 167 / 231

准确率 72.29%

不可与本页归一化分数混排。

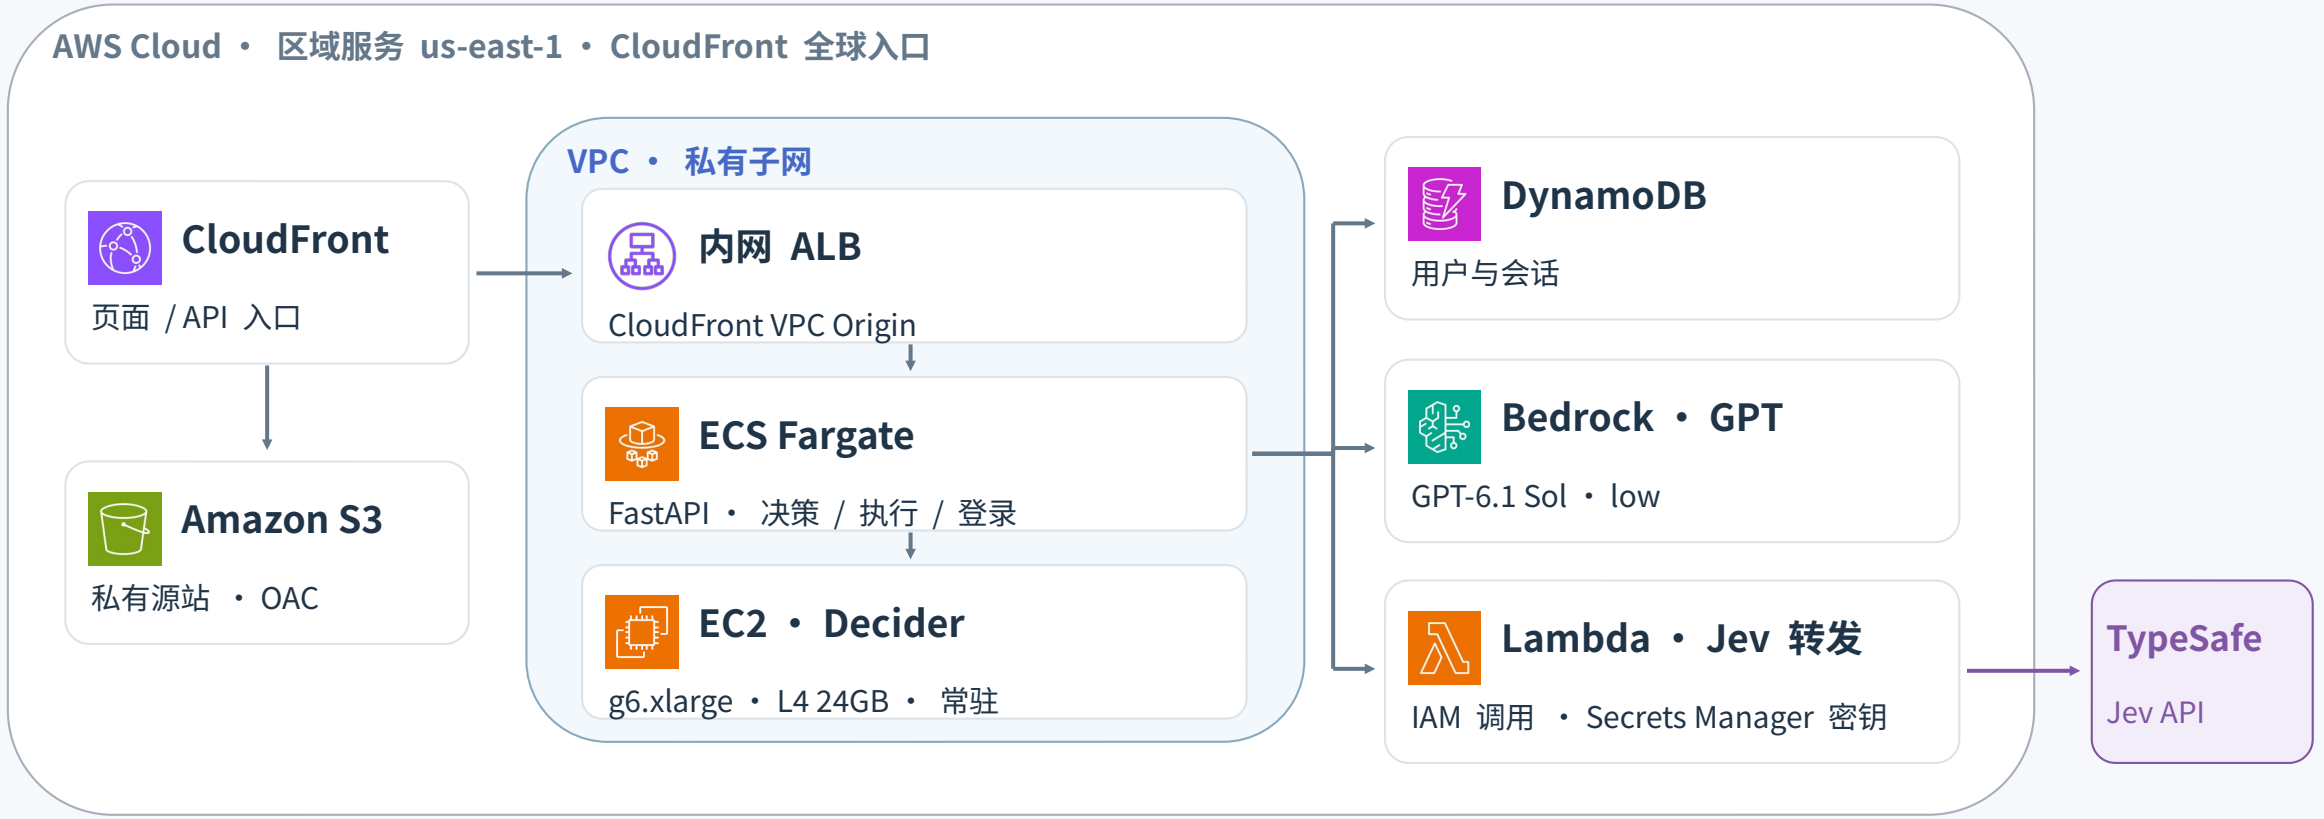
评测：benchmarkheaven.com/jev-models/api

Decider 来源：官方 v19 模型卡

公开基准用于筛选候选模型；是否适合你的支付策略，需要在真实业务输入上重新验证。

一套业务后端，连接三个模型

us-east-1 · 私有 S3 + CloudFront OAC · ECS Fargate · EC2 g6.xlarge / L4



自建用户名登录；业务后端统一校验候选和执行条件。图省略网络端点与非主路径的运维组件。

四个支付场景，贯穿五个业务节点

同一笔业务，分别交给 Decider 、 Jev 和 GPT 。

未到账

确认数 3 / 12

少付

100 → 99.80

退款

地址与审批待补齐

结算

到账状态与时效

客服受理

节点 1

→

交易核验

节点 2

→

风控审批

节点 3

→

业务处置

节点 4

→

回复结案

节点 5

客户消息、事实快照与候选条件均可追溯。

真实界面：同一输入，三模型输出并排看

相同事实、问题和候选条件；保留各自的原始选择、耗时与实际执行。



先看原始选择，再看实际动作；模型给出建议，业务系统负责执行。

四场景总览： Decider 最快，两处选择仍有差异

每格：该场景五步累计后端耗时 · 与演示参考一致次数

业务场景	Strands Decider	Jev 1.13.0	GPT-6.1 Sol
USDC 未到账	0.557 s · 5/5	2.318 s · 5/5	8.537 s · 5/5
USDT 少付	0.514 s · 4/5	1.896 s · 5/5	4.171 s · 5/5
稳定币退款	0.564 s · 4/5	2.112 s · 5/5	5.453 s · 5/5
商户结算	0.408 s · 5/5	2.003 s · 5/5	4.173 s · 5/5
20 步合计	2.043 s · 18/20	8.329 s · 20/20	22.335 s · 20/20

102.2 ms
平均每次后端耗时

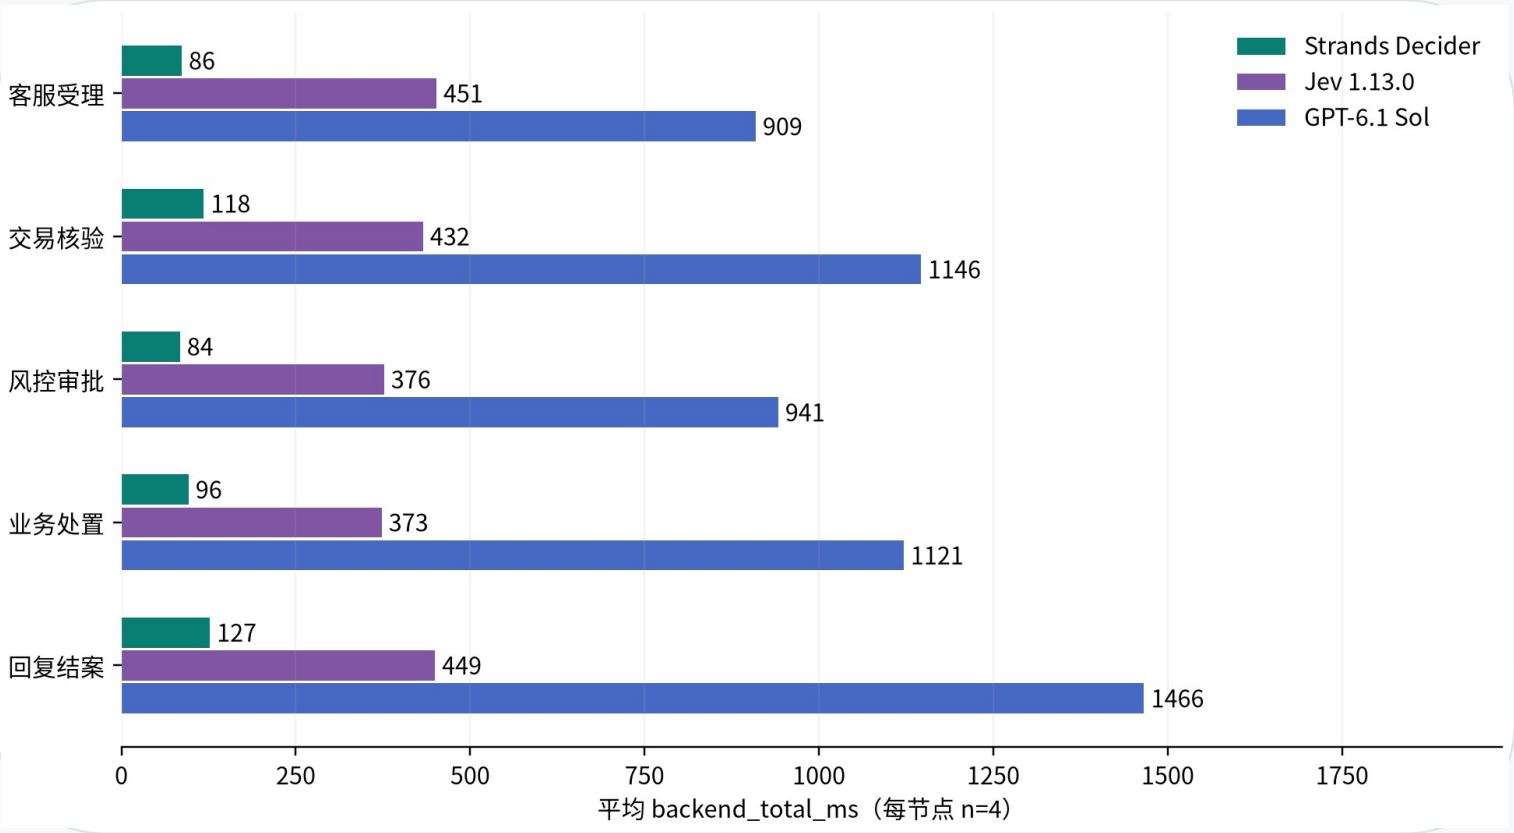
416.5 ms
平均每次后端耗时

1116.7 ms
平均每次后端耗时

预热后： Jev / Decider = 4.08×； GPT / Decider = 10.93×； GPT / Jev = 2.68× 。耗时含通信与后端处理。

逐节点看速度：受理、核验、审批、处置、回复

左侧比较各节点平均耗时；右侧查看每个模型的请求中位数。



Strands Decider

81.3 ms

Jev 1.13.0

397.7 ms

GPT-6.1 Sol

863.4 ms

右侧： 20 次请求中位数

每节点各 4 次；每模型共 20 次。比较的是应用调用耗时，不能当作模型纯计算时间。

USDC 未到账：三模型都等待确认

129 USDC 已足额；确认 3/12 。审批可通过，资金仍不能入账。

业务节点	Strands Decider	Jev	GPT
客服受理	支付客服 • 109 ms	支付客服 • 550 ms	支付客服 • 1108 ms
交易核验	等待链上确认 • 137 ms	等待链上确认 • 514 ms	等待链上确认 • 885 ms
风控审批	规则检查通过 • 76 ms	规则检查通过 • 364 ms	规则检查通过 • 1176 ms
业务处置	挂起并跟进 • 155 ms	挂起并跟进 • 461 ms	挂起并跟进 • 2084 ms
回复结案	回复并持续跟进 • 81 ms	回复并持续跟进 • 429 ms	回复并持续跟进 • 3284 ms



一致的判断：等待确认 → 检查通过 → 挂起并跟进。

USDT 少付：确认已够，仍需补款

应付 100 ，到账 99.80 USDT ；确认 20/12 。差额 0.20 才是当前阻塞。

业务节点	Strands Decider	Jev	GPT
客服受理	支付客服 • 82 ms	支付客服 • 439 ms	支付客服 • 873 ms
交易核验	等待链上确认 • 110 ms	请求补足差额 • 394 ms	请求补足差额 • 820 ms
风控审批	规则检查通过 • 105 ms	规则检查通过 • 365 ms	规则检查通过 • 855 ms
业务处置	挂起并跟进 • 79 ms	挂起并跟进 • 322 ms	挂起并跟进 • 798 ms
回复结案	回复并持续跟进 • 138 ms	回复并持续跟进 • 376 ms	回复并持续跟进 • 825 ms



关键差异： Decider 等待确认； Jev / GPT 要求补款。

退款审批：原始建议与实际采用动作不同

250 USDC 退款；资金已核验，但地址未验证、人工审批未通过。

业务节点	Strands Decider	Jev	GPT
客服受理	退款专员 • 79 ms	退款专员 • 350 ms	退款专员 • 824 ms
交易核验	到账已核验 • 148 ms	到账已核验 • 348 ms	到账已核验 • 2006 ms
风控审批	规则检查通过 • 79 ms	验证退款地址 • 437 ms	验证退款地址 • 932 ms
业务处置	挂起并跟进 • 75 ms	挂起并跟进 • 385 ms	挂起并跟进 • 777 ms
回复结案	回复并持续跟进 • 183 ms	回复并持续跟进 • 591 ms	回复并持续跟进 • 914 ms



执行保护： Decider 「检查通过」→「验证地址」；三侧均挂起退款。

商户结算：先升级工单，再等待到账

4,800 USDC； 120 分钟未到账，演示 SLA 为 60 分钟。

业务节点	Strands Decider	Jev	GPT
客服受理	商户运营 • 75 ms	商户运营 • 466 ms	商户运营 • 831 ms
交易核验	结算超时 • 77 ms	结算超时 • 473 ms	结算超时 • 872 ms
风控审批	规则检查通过 • 75 ms	规则检查通过 • 339 ms	规则检查通过 • 802 ms
业务处置	升级结算工单 • 76 ms	升级结算工单 • 324 ms	升级结算工单 • 827 ms
回复结案	回复并持续跟进 • 105 ms	回复并持续跟进 • 402 ms	回复并持续跟进 • 841 ms



一致的判断：识别超时 → 升级结算工单 → 持续跟进；尚未对账结案。

为什么选择不同？先分清观察与解释

自然语言候选条件由模型近似判断；同一输入不保证同一选择。

已观察到

少付：确认已达标，仍等待
退款：条件不足，过早通过

Jev / GPT 本次符合参考
Decider 两处与参考不同

合理解释，待验证

条件组合与适用范围
训练分布和语言表达
候选评分与生成机制

不能把输出当内部思维链

概率不能代替检查

少付误选 confidence 0.814
退款误选 confidence 0.252

高置信也会错
需要业务校准与执行保护

GPT / Jev 的 20/20 是本批次参考一致； Decider 的概率分布是偏向证据，不是业务正确性的证明。

五步已处理，为什么三个模型都没有结案?

初始四场景都有未补齐的外部条件；固定输入运行不会自动改变证据。

模型返回

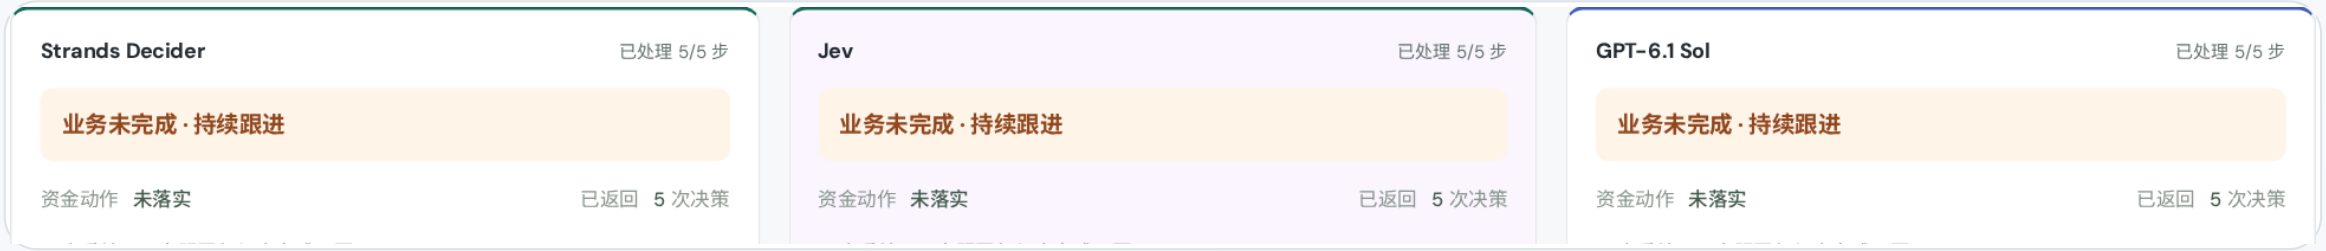
三个模型各 20/20 次成功

步骤处理

四场景均已处理 5/5 步

业务完成

初始证据下各 0/4 完成



仍缺什么? 未到账：确认达标 • 少付：补足差额 • 退款：地址与审批 • 结算：到账证据

完成标准：目标订单状态 + 对应模拟账本 + 工单结案。模型调用成功、选择正确、业务完成是三件事。

Jev 为什么没有宣传中的几十倍加速?

本批次 GPT / Jev = 2.68×；比较条件决定加速倍数。

Decider

ECS → 私网 EC2
本地部署的候选评分

Jev

ECS → Lambda → HTTPS
包含代理与外部往返

GPT

ECS → Bedrock
low 推理，只输出 ID

同一 Jev，两个观察位置	响应中位数	正确解读
JevBench API 公开结果	239.1 ms	第三方任务与测量网络
本项目支付 20 次调用	397.7 ms	含 Lambda、HTTPS 与后端处理

即使预热，网络往返与代理处理仍占用时间； GPT 只输出候选 ID，也会缩小速度差距。

闭环做了什么：等待证据、重新核验、完成入账

USDC 案例 · 三侧各 6 次决策 +1 次模拟确认事件，最终都完成。

实际检查

确认不足 → 暂停资金

模拟器事件

确认数 3/12 → 12/12

携带反馈重判

重新核验 → 入账 → 结案



三侧实际结果：订单已收款 · 模拟账本 129 USDC · 工单已结案

Decider 首轮误选「结算已核验」，执行检查仍等待确认；后续重判完成。完成闭环不代表每次选择都正确。

从选业务动作，到选择执行任务的模型

用户只输入任务；三个决策模型分别完成「选流程 → 选型号」。

任务输入

原始业务请求

无速度 / 成本优先级

→

决策 1

选择处理流程

客服 / 代码 / 分析 / 向量

→

决策 2

任务 + 已选流程

+ 候选能力证据

→

结果展示

真实型号与两步耗时

用户另行执行目标

程序提供事实与校验

区域可用性、模态、评测映射、候选 ID 合法性

模型决定流程与型号

保留原始选择；不按排名自动替换，不强制三者一致

两次 /api/routing/decision ；执行另用 /api/routing/execute 。本批未运行目标任务。

四个任务，统一的候选事实

第一步看任务；第二步再看已选流程及型号评测。

场景	任务核心	三者共同选中的流程
支付客服	USDC 已转出，确认数 3/12 ，解释待支付	直接答复客户
交易代码	Webhook 去重、验签、 Decimal 、并发入账与测试	编写代码与测试
结算分析	12000 应结算； 11880 到账； 0.8% 费率； 24 暂扣	核算与分析
中英文索引	将中英文支付工单转换为检索向量	生成检索向量

区域目录 124 条　文本候选 22 个　向量候选 3 个　LiveBench + MTEB

当前未启用 Artificial Analysis ；缺少评测映射的型号仍可在目录查看，但不进入本批候选。

路由实测：速度领先，选择质量仍需检验

每格：目标型号 / 两步累计后端耗时； 4 场景 × 3 模型 × 2 次调用。

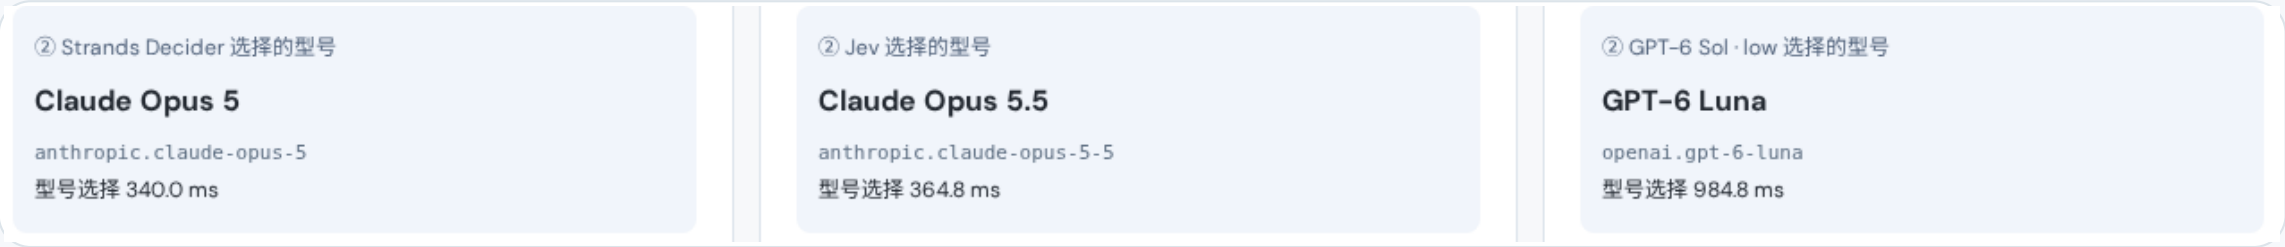
场景	Decider	Jev	GPT-6 Sol low
支付客服	Claude Opus 5 461.0 ms	Claude Opus 5.5 747.9 ms	GPT-6 Luna 1464.8 ms
交易代码	Claude Opus 5 522.6 ms	Claude Sonnet 5.5 933.3 ms	Claude Sonnet 5.5 6168.2 ms
结算分析	Claude Opus 5 504.6 ms	Claude Opus 5.5 820.4 ms	GPT-6.1 Sol 12106.1 ms
中英文索引	Embed English 182.2 ms	Embed Multilingual 801.7 ms	Embed Multilingual 1900.8 ms
两步均值	**417.6 ms**	**825.8 ms**	**5410.0 ms**

24/24 为有效返回，不是全部选对；每场景仅一次正式样本。首轮 GPT 超时另行保留。

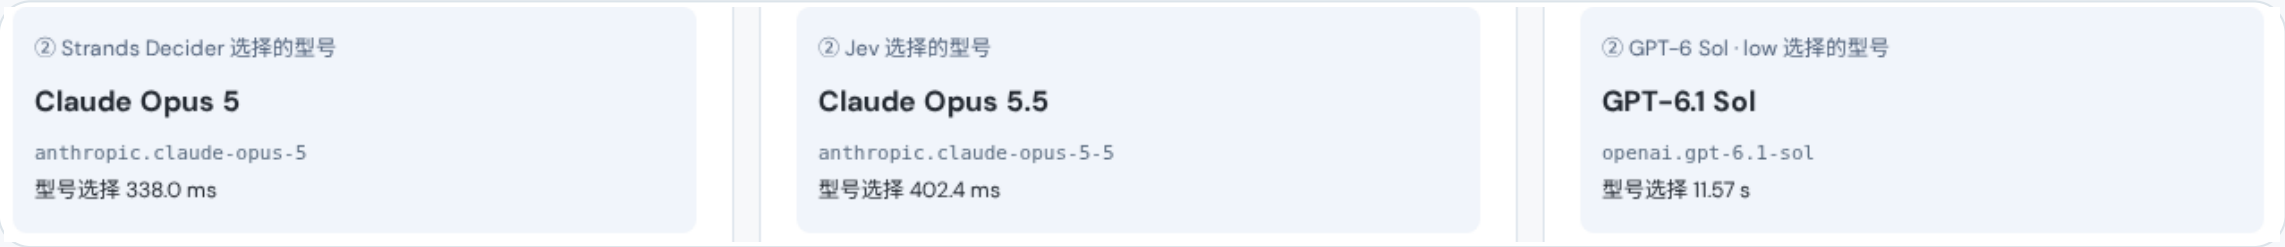
客服与分析：保留差异，验证目标任务后再判优劣

同一输入产生不同型号；当前没有目标回答质量、生成延迟或实际费用的比较。

支付客服



结算分析



来自真实结果截图的型号区域裁剪；没有修改图片内的选择或数据。

交易代码： Jev 与 GPT 更贴合代码能力证据

三者都识别代码任务； Decider 选 Opus 5 ，其余两者选 Sonnet 5.5 。



LiveBench Coding **Opus 5： 81.45** **Sonnet 5.5： 91.37**

Opus 5 综合分更高；接口没有给出选择理由。未生成并运行代码，不能直接断言代码一定失败。

中英文索引： Decider 的型号选择不合适

流程识别正确，但选择 Embed English； Jev / GPT 选择 Embed Multilingual 。



中文检索分 **English： 4.18** **Multilingual： 60.65**

MIRACL nDCG@10 × 100； 当时三者收到相同名称与正确均分，分语言成绩仅用于本页分析。

正确上下文，还需要模型正确使用证据

改善输入协议不等于训练了模型； vLLM 提速也不会自动修正选型错误。

已观察

三者流程识别均正确
Decider 索引型号选错
代码选型依据较弱

能得出的结论

当前索引任务 Jev / GPT 更好
代码选择更符合评测证据
客服、分析需目标任务验证

下一步验证

更多任务与语言变体
打乱候选顺序做对照
运行目标任务，测质量与成本

当前建议：优先继续评估 Jev 做模型选型； Decider 需要专项质量验收。

四个任务不足以得出通用排名；没有内部推理证据，不能编造品牌偏好或指标权重作为原因。

优化示例：让退款审批只作用于退款

已验证的前后对照 · USDC 收款 · 只调整输入字段与候选条件

真实界面入口

测试方式 优化流程

精简字段 → 明确适用场景 → 重新判断

固定流程

收款事实 + refund_approved=false
退款字段仍出现在普通收款输入中

Decider： 等待人工审批	75.7 ms
GPT： 规则检查通过	1,080.1 ms

优化流程

收款事实，移除无关退款字段
候选明确：非退款不要求退款审批

Decider： 规则检查通过	80.2 ms
GPT： 规则检查通过	820.3 ms

本次优化改变输入与条件表述；候选 ID 、模型权重和执行校验保持一致。

确认数仍为 3/12： 两侧资金继续挂起。审批选择改善，不表示已经到账。

已验证的优化： Decider 参考一致 14/20 → 18/20

明确候选适用范围、去除无关字段，减少两类业务条件之间的混淆。

业务场景	Decider 固定	Decider 优化
USDC 未到账	4/5	5/5
USDT 少付	4/5	4/5
稳定币退款	2/5	4/5
商户结算	4/5	5/5
合计	14/20	18/20

已验证的变化

参考一致改善；保护调整 4 → 1
模型权重未变，未进行领域微调。

当前三模型再次观察

Decider 18/20 · Jev / GPT 20/20
剩余：少付核验、退款审批
仍需下一轮优化与独立测试。

优化输入已减少选择错误；模型权重未变。少付核验与退款审批仍需改进。

下一步优化：把剩余错误变成可重复的测试

优先改问题表达与任务拆分，再判断是否需要改模型权重。

收集错误

事实 + 候选 + 原始选择

实际执行 + 人工正确动作

→

构造最小对照

只改一个条件或边界

加入近似反例与语言变体

→

验证改动

冻结测试集与版本

比较错误、延迟和完成率

少付：把确认与金额分开

确认达到阈值后，明确跳过等待确认；

用差额 0 / 0.01 / 0.20 测补款分支。

退款：先限定场景，再检查前提

地址验证 → 人工审批 → 执行资格；

覆盖缺失、冲突、风险优先等反例。

这是后续实验方案，未宣称已提升效果；参考与真实执行保护必须独立于模型输出。

需要微调时：训练决策能力，不只训练 JSON 外形

沿用官方训练链路，适配 LoRA 与 Pointer Head；先准备独立领域评测。

领域样本

真实案件去标识

覆盖正常与困难反例

→

人工标注

正确候选 / 判断依据

教师模型只辅助

→

参数适配

LoRA + 候选评分头

沿用类型化决策目标

→

独立评测

保留集 + 校准 + 延迟

灰度验证与可回滚

必须守住的边界	目的
按案件、模板簇、时间切分	避免同义样本跨训练与测试集泄漏
保留通用任务与所有问题类型的回归集	防止领域改善伴随能力退化
执行保护独立；上线前核验实际业务结果	不把微调后的高置信选择直接当资金授权

当前演示没有修改模型权重；本页是下一阶段实施方法，尚无微调后的成绩或成本承诺。

vLLM 适配：保留决策头，换成并发调度

继续输出候选 ID 、概率与置信度；不改造成逐 token 生成 JSON 。

官方输入处理

模板、 tokenizer

每请求独立候选位置

→

vLLM 调度

Qwen3.5 + 已合并 LoRA

完整 prefill 隐藏状态

→

Pointer Head

GPU 候选评分 + 温度校准

BF16 底座 / FP32 头

→

原答案转换

choice / noul / score

/v1/systemone

保留

官方模板、候选语义、权重与数值校验

改变

多请求进入引擎调度， GPU 批量候选评分

自定义 pooling 插件需要候选位置 metadata ； 普通 chat/completions 接口不是等价替代。

部署过程：导出 → 校验 → 容器 → 对齐

固定 vLLM 0.31.0 与官方 Decider 源码提交；通过独立服务验证后再考虑集成。

1 合并导出

官方加载器合并 LoRA

保留原 head.safetensors

2 检查产物

清单与 SHA-256 校验

不覆盖已有权重目录

3 GPU 启动

Docker + NVIDIA Runtime

单 Uvicorn worker

4 真实对齐

选择一致；概率 / 置信度

绝对偏差阈值 0.02

```
decider-vllm export --checkpoint CHECKPOINT --base BASE --output MODEL
decider-vllm verify-artifacts --model MODEL
decider-vllm serve --model MODEL --max-num-seqs 128 --max-num-batched-tokens 8192
```

完整 prefill；前缀缓存、分块预填充和 CUDA Graph 均关闭。多问题独立提交，完整命令见来源链接。

独立公共 API：私网源站，GPU 持续驻留

与原支付 / 路由演示并行运行；当前演示仍调用官方原版推理服务。



调用方

Bearer API Key

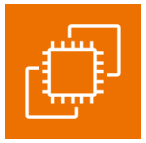
POST /v1/systemone



CloudFront

HTTPS

VPC Origin 私网访问



EC2 g6.xlarge

单张 L4 · 常驻

vLLM 模型容器



EBS gp3

160 GB 加密盘

权重与运行缓存

部署：私有 S3 / ECR → SSM 安装与校验 → systemd 常驻 → HTTPS 验证

https://d1e9udi8st2p3g.cloudfront.net/docs

服务端 HTTP / 问题准入 256；引擎序列上限 128。它们是上限，不代表 GPU 吞吐保证。

压测怎么做：固定输入，完整响应后再补请求

20 条支付步骤输入；每个请求只包含一个选择题，测的是单次决策。

输入与用量

四场景 × 五个独立步骤

Decider： 304–445 tokens

平均 373.9 tokens

Jev： 575–744 tokens

平均 656.95 tokens

负载与样本

并发： 1 → 128

固定数量 worker

每档 1280 次正式请求

每条输入重复 64 次

预热另存；失败不重试

计时与统计

客户端至完整响应

包含网络、排队与处理

RPS = 成功数 / 总时间

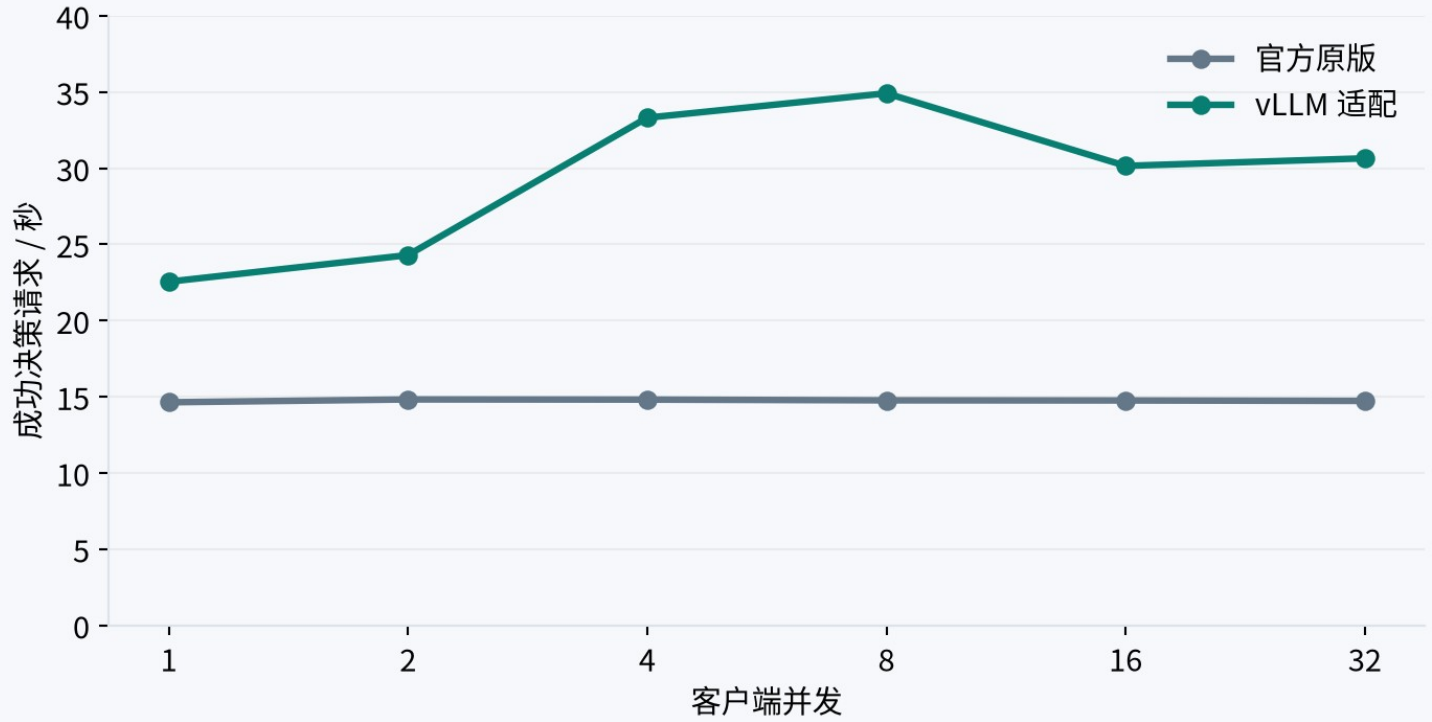
P95 仅统计成功响应

失败与数值偏差另报

本页为公网 1–128 扫描口径。两服务 tokenizer / 用量口径不同；重复请求不是独立业务质量样本。

同一块 L4： vLLM 在 8 并发约提升 2.36 倍吞吐

相同权重与输入，两个服务分别独占 GPU；完整复测每档 80 次。



8 并发吞吐

14.76 → 34.91 次 / 秒

8 并发 P95

542.8 → 237.6 ms

g6.4xlarge 同机；推理容器限制 4 vCPU / 14 GiB。三轮共 5 次超时保留；收益不只来自批处理。

1–128 并发：吞吐进入平台，等待时间持续增加

g6.xlarge · 单 L4 · 8192 token 预算；每档 1280 次，全部成功。

并发	成功次 / 秒	平均 ms	P95 ms	P99 ms
1	18.10	55.1	59.9	63.7
2	22.85	87.4	89.9	91.7
4	33.11	120.6	131.8	135.2
8	33.84	236.0	245.0	247.0
16	29.34	544.4	561.8	572.7
32	30.06	1057.9	1089.9	1103.5
64	29.76	2112.7	2178.7	2822.1
128	29.65	4111.9	4986.1	7568.0

8 并发：33.84 次 / 秒　　128 并发：29.65 次 / 秒，P95 4.99 秒

含高并发复测共 12800 次成功；一次置信度差 0.0202 超过 0.02 阈值，候选选择仍一致。

批次 token 预算更大，没有提高这批短输入吞吐

每格为成功次 / 秒 / P95 毫秒；只改变 max_num_batched_tokens 。

并发	8192 tokens	16384 tokens	32768 tokens
8	37.01 / 231.0	33.67 / 242.7	34.27 / 242.2
16	30.55 / 546.1	30.50 / 547.7	30.71 / 535.0
32	30.34 / 1069.5	29.94 / 1081.9	29.78 / 1087.2
64	30.20 / 2137.2	29.75 / 2189.4	29.67 / 2200.0
128	29.92 / 4932.3	29.61 / 5166.7	29.44 / 5983.9

当前保留 8192；先测实际批次和各层耗时，再决定下一项优化。

本表使用该实验自己的基线；含复测共 23040/23040 成功。预算是上限，不等于实际批大小。

vLLM vs Jev： 低并发延迟与高并发吞吐各有优势

相同 20 条业务输入、相同客户端； Decider 经 CloudFront， Jev 直接访问供应商 API 。

并发	vLLM 次 / 秒	平均 / P95 ms	Jev 次 / 秒	平均 / P95 ms
1	18.01	55.4 / 59.4	7.90	126.5 / 160.2
2	22.53	88.6 / 91.0	15.39	129.8 / 171.2
4	32.76	121.8 / 134.6	30.27	131.7 / 166.7
8	35.74	223.4 / 237.0	61.83	128.9 / 166.9
16	33.61	474.7 / 539.4	127.45	123.5 / 156.9
32	30.61	1039.2 / 1073.1	240.94	130.0 / 172.6
64	30.19	2081.0 / 2128.5	68.15	921.2 / 4059.0
128	30.59	3981.9 / 11236.8	52.56	1743.5 / 5502.5

正式成功： vLLM 10239/10240， Jev 10240/10240；预热各 560 次另存。两者基础设施不同。

选择并发档位，要同时看尾延迟与失败

Jev 32 并发较长复测保持约 245 次 / 秒； 128 并发出现明显退化。

低并发

并发 1 平均延迟

vLLM： 55.4 ms

Jev： 126.5 ms

本批 vLLM 更快

中等并发

并发 32 成功吞吐

vLLM： 30.61 次 / 秒

Jev： 240.94 次 / 秒

本批 Jev 更高

高并发尾部

并发 128 的 P95

vLLM： 11.24 秒

Jev： 5.50 秒

继续加并发会增加等待

vLLM 有一次 HTTP 502 、十次数值偏差超阈值； Jev 128 并发较长复测 P95 7.31 秒。均保留。

成本： g6.2xlarge 常驻，与 Jev 按量计费

us-east-1 · Linux On-Demand · USD ；以真实 token 用量计算公开单价估算。

Strands Decider 自部署

$0.9776 / 小时

730 小时： $713.65 / 月

160 GB gp3 ： 另加 $12.80 / 月

计算 + 磁盘： $726.45 / 月

Jev API

$0.042 / 百万输入 tokens

输出免费

实测每次平均 656.95 输入 tokens

约 $27.59 / 百万次决策

实测 10240 次 Jev 请求： 6727168 输入 tokens → 按公开价约 $0.283

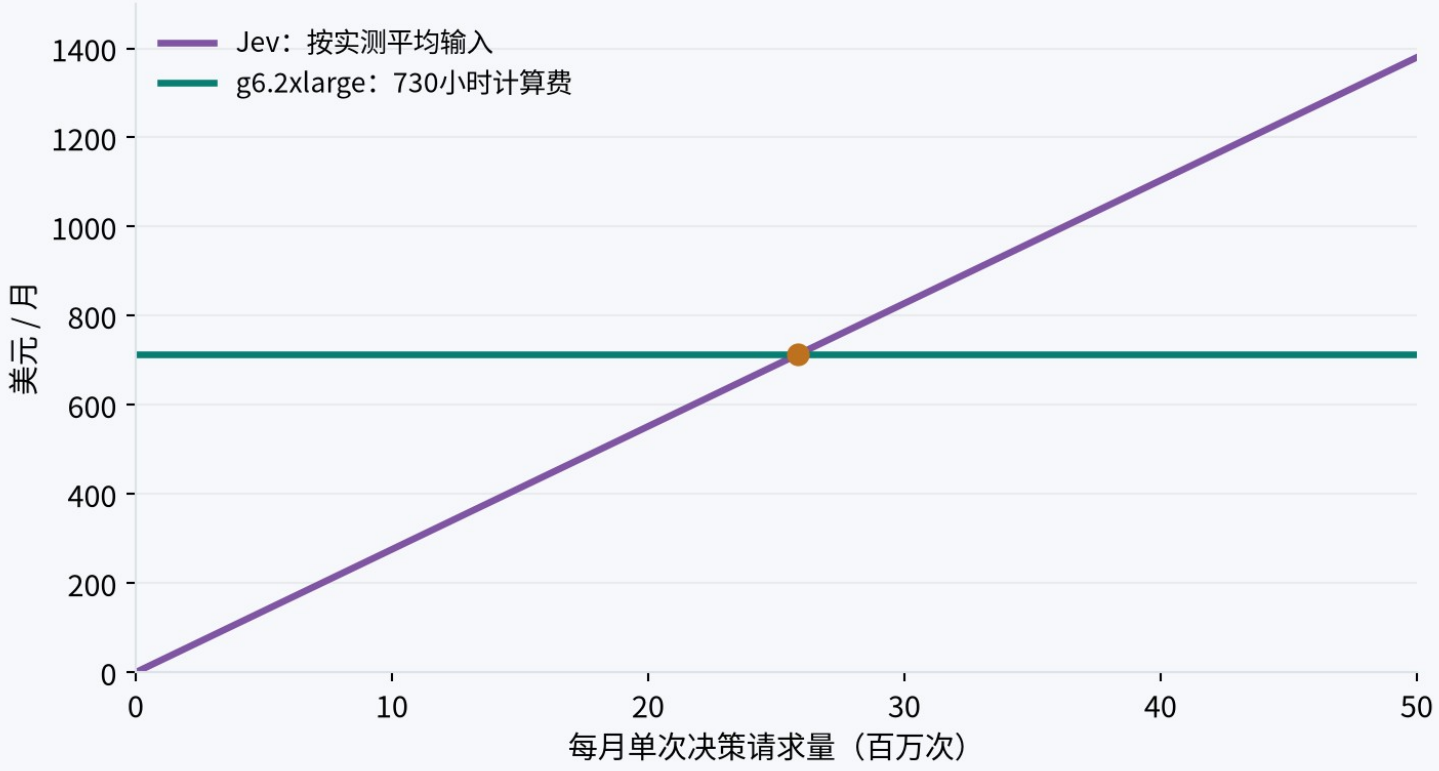
来源：AWS 按需价格

来源：Jev 官方价格说明

公开价估算，不是账单。 g6.2xlarge 未实测容量；本页不将 g6.xlarge 吞吐直接套用。

按这批短输入，约 2586 万次 / 月达到计算费交点

一次决策平均 656.95 Jev 输入 tokens；常驻 GPU 即使空闲也计时收费。



月决策量	Jev	EC2 计算
1 百万	$27.59	$713.65
10 百万	$275.92	$713.65
30 百万	$827.76	$713.65

交点平均约 9.84 次 / 秒

加磁盘后约 2633 万次 / 月

交点仅比较费用公式，不保证单卡满足容量或 SLA；网络、运维、冗余、折扣、税费另计。

任务变长、一次路由两次判断，成本也会改变

用路由实测的 Jev usage 重新计算；不能套用支付单步的 656.95 tokens 。

路由任务	两次调用输入 tokens	Jev / 百万次完整路由
支付客服	3271	$137.38
交易代码	3304	$138.77
结算分析	3309	$138.98
中英文索引	1339	$56.24

四场景等权平均： $117.84 / 百万次路由

g6.2xlarge 计算费交点约 606 万次路由 / 月；目标模型执行费用另计。

这是同等四场景配比的价格模型，非月度实测账单；尚未测量 g6.2xlarge 对路由长输入的吞吐。

落地方式：常见判断用小模型，复杂异常升级

先按业务效果建立分流，再用真实用量评估总体成本。

业务请求

消息 + 经过核验的事实

任务分流

明确、常见 → 小模型

复杂、冲突 → GPT / 人工

执行系统

检查条件、权限与账本

记录结果，反馈再判断

质量

按场景错误率

高风险误放行

校准与自动化覆盖率

性能

同任务重复测量

p50 / p95 / p99

吞吐、失败与超时

业务与成本

实际完成率与人工介入

常驻 GPU 利用率

托管用量与基础设施

置信度阈值应在独立业务集上校准；高置信也可能出错，执行保护始终独立。

支付演示回顾：速度、选择和真实业务结果

公开基准帮助选型；项目实测解释行为；独立评测验证优化。

模型	当前观察	适合继续验证的方向
Strands Decider	102.2 ms / 次 · 18/20	可自行部署的高频有限判断
Jev 1.13.0	416.5 ms / 次 · 20/20	托管决策、概率与接入成本
GPT-6.1 Sol	1116.7 ms / 次 · 20/20	复杂语义、异常处理和开放式生成

已验证：输入优化改善选择

待验证：领域微调与生产收益

本批次 20 个不同任务，不代表通用准确率或稳定延迟；四个初始场景均需外部条件才能完成资金业务。

最终选型：质量、性能、成本分别验收

同一模型可以决策很快，同时仍在某些业务上选错；引擎优化与质量优化分开推进。

路由质量

索引选型： Jev / GPT 优于 Decider 。
扩大任务集，并运行目标任务验收。

推理性能

同机 8 并发吞吐约为原版的 2.36 倍。
公网先从 4–8 并发评估负载。

托管服务

Jev 在本批 8–32 并发时吞吐更高。
提高并发前，核对尾延迟与失败。

成本决策

低用量优先评估按量服务。
高稳定用量再核算自部署与运维。

本版使用已有实测与当日公开价格；没有进行新的微调、 g6.2xlarge 压测或原演示的引擎迁移。

打开 Demo，查看三模型过程与原始记录

从相同业务输入开始，核对每一步的建议、实际动作、耗时与最终结果。

在线 Demo

支付流程 + 模型路由
使用现有账号登录

https://d3i7ogfx5ml7dc.cloudfront.net/#crypto

GitHub Repo

公开仓库 · 架构、代码、资料与实测记录

https://github.com/milan9527/StrandsDecider

vLLM 项目 github.com/milan9527/StrandsDeciderVLLM

路由入口： Demo /#routing · vLLM API： d1e9udi8st2p3g.cloudfront.net/docs · 基准及来源见讲稿。