让决策模型接得住真实业务

Strands Decider 、 Jev 与 GPT ： 从原理、业务验证，到 vLLM 部署与成本选择

选得对

业务事实 → 候选动作

核对证据和完成条件

跑得动

单次延迟 → 并发吞吐

看完整请求和尾延迟

算得清

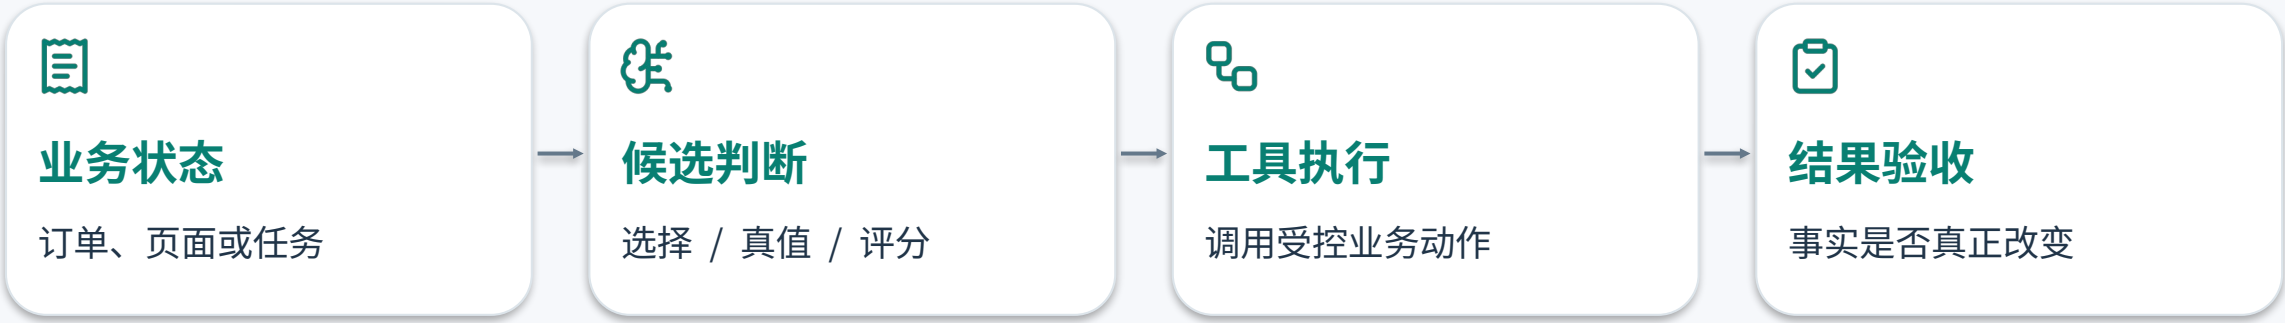
自托管 → 按量 API

加入 EC2 RI 长期承诺

v11 • 2026-10-15 | 实验来自保存的真实请求；价格按当日 AWS / Jev 公开口径。

业务流程里，很多步骤只需要一个选择

客服分流、证据核验、工具选择、模型路由：输出很短，判断会高频重复。



选择

与预先定义的参考比较

结果

查看页面、账本或产物

性能

记录延迟、吞吐和成本

适用前提：可定义候选、可取得事实、可验证执行结果。开放式写作仍需要生成模型。

Decider： 读完上下文，直接给候选评分

公开 v19： Qwen3.5-2B 底座 + LoRA + Pointer Head； 不逐 token 生成答案。

提交业务事实

state + questions

→

单次前向计算

2B 底座 + rank-16 LoRA

→

Pointer Head

对当前候选评分

→

类型化结果

choice / noul / score

共享上下文

同一请求可含多个独立判断，减少重复输入。

依赖执行结果的下一步

先执行并更新状态，再发起新判断。

来源： Strands 官方介绍与 v19 实现。 API 的 probability / confidence 不是业务正确率。

相同候选问题，可以通过不同模型回答

应用先定义问题和可执行选项；模型负责选择，执行器负责真正改变业务状态。

维度	BERT 分类器	Decider / Jev	GPT
典型输出	固定标签	候选 ID 、真值、评分	文本或结构化 JSON
新增任务	标签与领域训练适配	提交事实、问题、候选	提交指令与上下文
实现	编码器 + 分类头	Decider 评分头； Jev API	生成式模型
适合	稳定标签的专用分类	高频、有限动作的判断	开放式分析、写作、代码

同一个 approved ，可能来自分类头、候选评分或文本生成；都需要核对业务条件。

BERT 的 NLI 用法也可比较文本候选；此处比较典型分类头，没有进行 BERT 实测。

JevBench： 同时看能力、校准、速度与成本

公开 API 榜单节选；综合分低，不代表回答正确率同样低。

模型	综合分	能力轴分	延迟 P50
Jev 1.13	71.5	63.6	0.239 s
GPT-6 Luna low	40.5	96.6	1.854 s
Gemini 3.1 Flash Lite	16.9	58.6	0.957 s
DeepSeek V4.1 Flash	7.1	94.7	2.038 s
Qwen3.8 27B	0.0	96.4	7.095 s

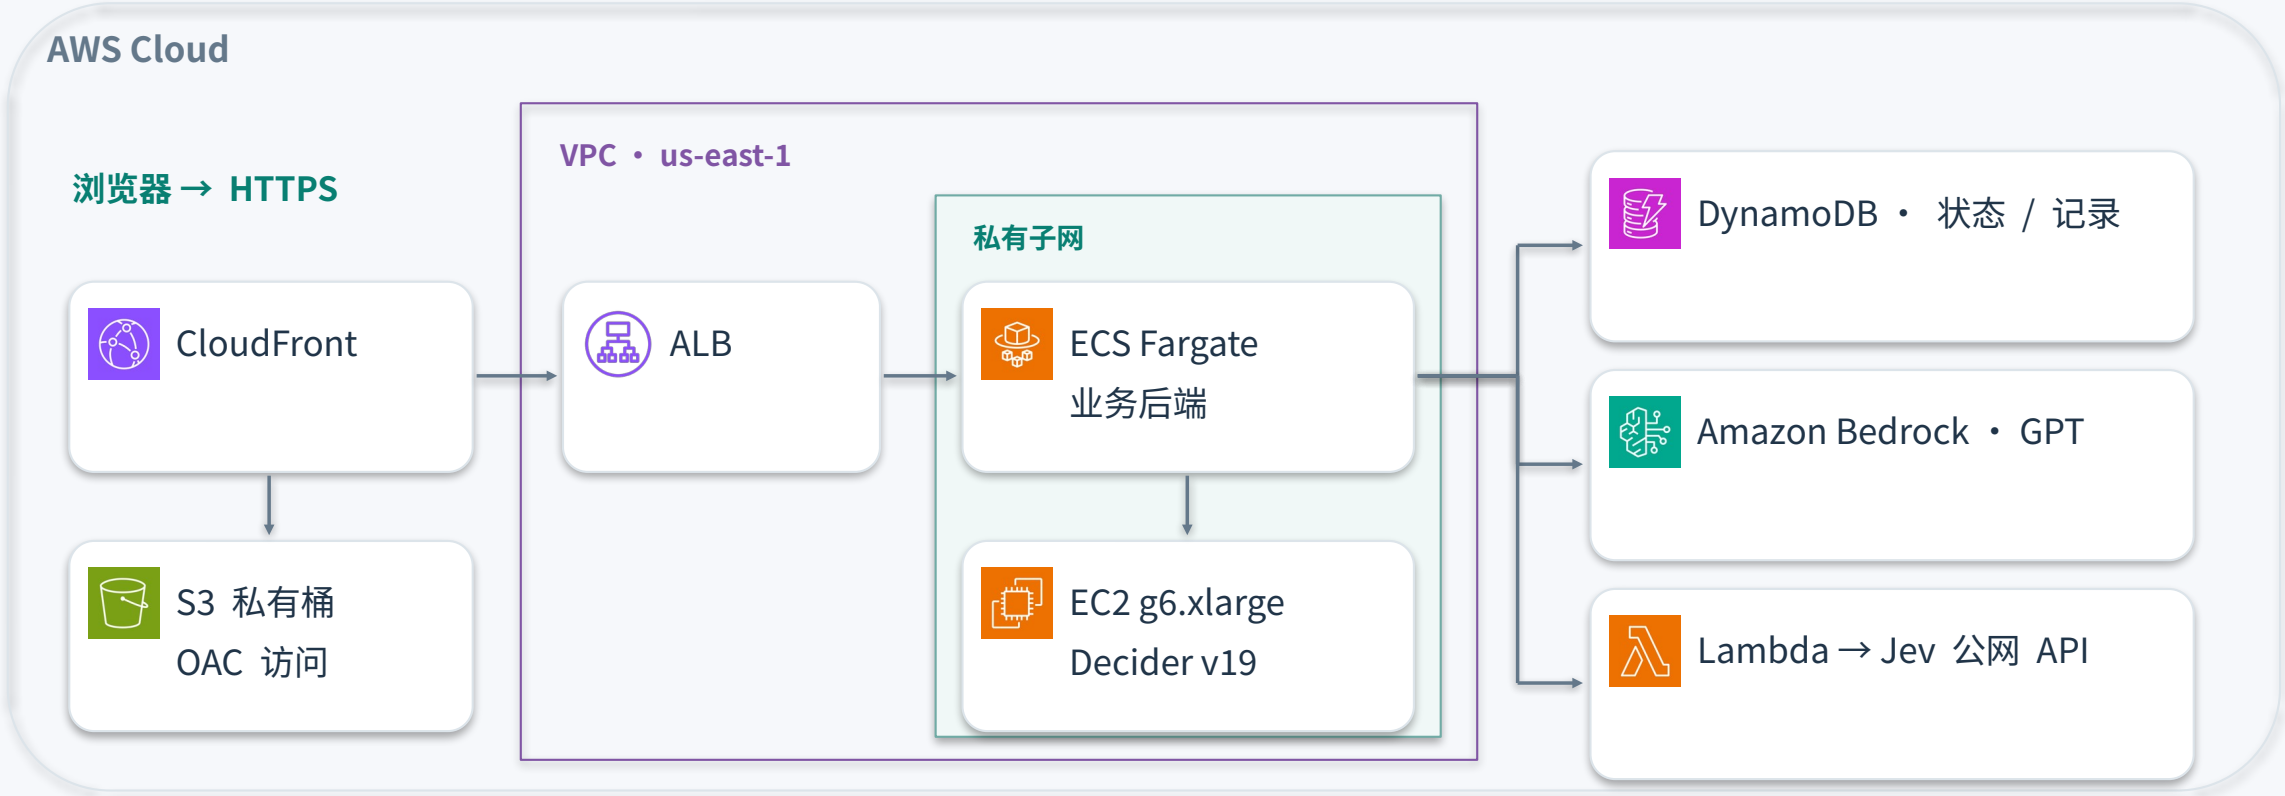
例如： Qwen 的能力轴高，但速度等轴拉低综合分。选型时应分别查看各轴。

评测与方法：benchmarkheaven.com/jev-models/api

榜单 v1.7.46 快照： 2026-10-12 。第三方公布结果，本项目未重跑，也不是 AWS 官方评分。

同一业务后端，连接三个决策模型

前端 S3 + CloudFront OAC ； 用户名登录； ECS 执行支付、路由与结果记录。



主演示使用原版 Decider g6.xlarge 常驻服务；独立 vLLM API 见第 25 页。

四个场景，同样经过五个业务节点

提交业务事实、问题与候选项；三个模型使用相同输入，分别推进各自的业务状态。

客服受理
识别用户诉求

→

交易核验
确认数 / 金额

→

风控审批
风险 / 退款地址

→

交易处置
等待 / 补款 / 入账

→

客服回复
跟进 / 结案

USDC 未到账
129 USDC；确认数 3/12

USDT 少付
应付 100；实收 99.80

稳定币退款
退款地址尚未验证

商户结算
已超过 60 分钟 SLA

模型建议、实际执行动作、对话输入输出和最终业务结果分别记录。

Decider 响应最快，两个节点仍选错动作

每格为五个节点的请求耗时之和 · 与演示参考一致次数。

场景	Decider	Jev	GPT
USDC 未到账	0.557 s · 5/5	2.318 s · 5/5	8.537 s · 5/5
USDT 少付	0.514 s · 4/5	1.896 s · 5/5	4.171 s · 5/5
稳定币退款	0.564 s · 4/5	2.112 s · 5/5	5.453 s · 5/5
商户结算	0.408 s · 5/5	2.003 s · 5/5	4.173 s · 5/5

102.2 ms

单节点平均 · 18/20 与参考一致

416.5 ms

单节点平均 · 20/20 与参考一致

1116.7 ms

单节点平均 · 20/20 与参考一致

2026-10-12 预热后批次， 60 次正式调用。 GPT 为 GPT-6.1 Sol low ； 不是最终资金完成率。

退款：模型批准了，执行器仍要求验证地址

真实界面保留三模型的原始输出；保护逻辑修正执行，不替模型“改成绩”。



退款偏差

地址未核验，却选择 approved 。

少付偏差

确认数已够，却等待更多确认。

实际截图： refund-decision.png ；少付与退款都计作 Decider 选择偏差。

闭环由新事实推动：确认到账，再入账和结案

USDC 沙盒：模拟器推进确认数，执行器更新订单；模型读取执行结果后重新选择。

等待确认

当前 3 / 12

→

推进模拟交易

确认数变为 12 / 12

→

重新核验

金额足额且已确认

→

入账并结案

129 USDC 已入账



五步都返回答案 ≠ 业务已完成。以入账记录、订单状态与工单状态验收。

保存的闭环批次：各模型 6 次决策 +1 次模拟推进；不是链上真实资金交易。

用户只给任务，决策模型先选流程、再选型号

服务端补充可用模型与能力资料；三个决策模型比较同一份候选证据。

任务原文

客服 / 代码 / 分析 / 索引

第 1 次判断

直接答复、代码、分析、向量

补充模型资料

区域可用性 + 第三方排名

第 2 次判断

从流程候选中选型号

候选事实

LiveBench 等文本证据； MTEB / MIRACL 向量证据。

本次测到的范围

两次路由选择与耗时；尚未执行选中的下游模型。

区域目录快照 124 项；文本流程 22 个候选，向量流程 3 个候选。

流程判断一致，具体型号选择出现差异

每格为所选型号与两次决策总耗时； GPT 决策器为 GPT-6 Sol low 。

任务	Decider	Jev	GPT
高频客服	Opus 5 461.0 ms	Opus 5.5 747.9 ms	GPT-6 Luna 1464.8 ms
交易代码	Opus 5 522.6 ms	Sonnet 5.5 933.3 ms	Sonnet 5.5 6168.2 ms
结算分析	Opus 5 504.6 ms	Opus 5.5 820.4 ms	GPT-6.1 Sol 12106.1 ms
中英文索引	Embed English 182.2 ms	Embed Multilingual 801.7 ms	Embed Multilingual 1900.8 ms

代码任务： Jev / GPT 选 Sonnet 5.5 ；中英文索引： Decider 选了英文向量模型。

2026-10-13 · 四任务各测一次；型号选择差异不能直接当作下游任务准确率。

拿到了同一上下文，仍可能没有选对证据

中英文工单索引的真实截图：三侧都选向量流程， Decider 选择 Embed English 。



中文检索证据

MIRACL 中文： English 4.18 ； Multilingual 60.65 。

代码能力证据

Coding ： Sonnet 5.5 为 91.37 ； Opus 5 为 81.45 。

输入提供均值、型号名与配置信息；下方中文分项用于事后诊断，当时未逐项提供给模型。

从演示样例，扩展到 466 次有记录的调用

Decider v19 原版服务 vs Jev 1.13.0；这轮验证没有 GPT，也没有使用 vLLM。

实验	评分单位	Decider	Jev	真实调用
Skills	65 个可判定问题	50/65	65/65	64
真实浏览器	5 任务 × 2 轮	4/10 完成	10/10 完成	58
金融业务	30 题，原始顺序	22/30	28/30	120
政策路由	32 题 × 2 顺序	25/64	46/64	224*

* 路由 224 次包含自然语言候选诊断；金融 120 次包含两种候选顺序。

有效返回 466/466，说明接口能完成请求；业务选择和任务完成需要另外评分。

问题数、任务数与请求数不同，不计算跨场景总准确率；来源：validation/README.md。

分类与局部选择接近，证据核验拉开差距

32 个输入包含多个独立问题； 68 个返回中， 3 个歧义问题只验协议、不计语义成绩。

业务用途	Decider	Jev
分类 / 意图	13/13	13/13
工具 / 局部动作	10/10	10/10
上下文筛选	6/6	6/6
恢复 / 完成检查	7/8	8/8
证据核验	11/20	20/20
等级评分	3/8	8/8

本批客户端 RTT 中位数： Decider 164.6 ms； Jev 119.9 ms 。

典型偏差：任务还在排队却选择结束；断言换成 assert True 仍支持完成。

参考在调用前冻结；按业务用途事后归类。量表采用固定 ±0.5 容差。

多步操作要验收目标页面，不能只看 finish

模型读取页面文字与 DOM， Playwright 执行真实点击、填写与搜索。

任务	Decider	Jev
Wikipedia： Basel III 搜索	0/2	2/2
CFPB：信用卡账单争议	0/2	2/2
ECB：美元汇率详情	2/2	2/2
FDIC：保险 FAQ	2/2	2/2
FDIC：银行机构查询	0/2	2/2

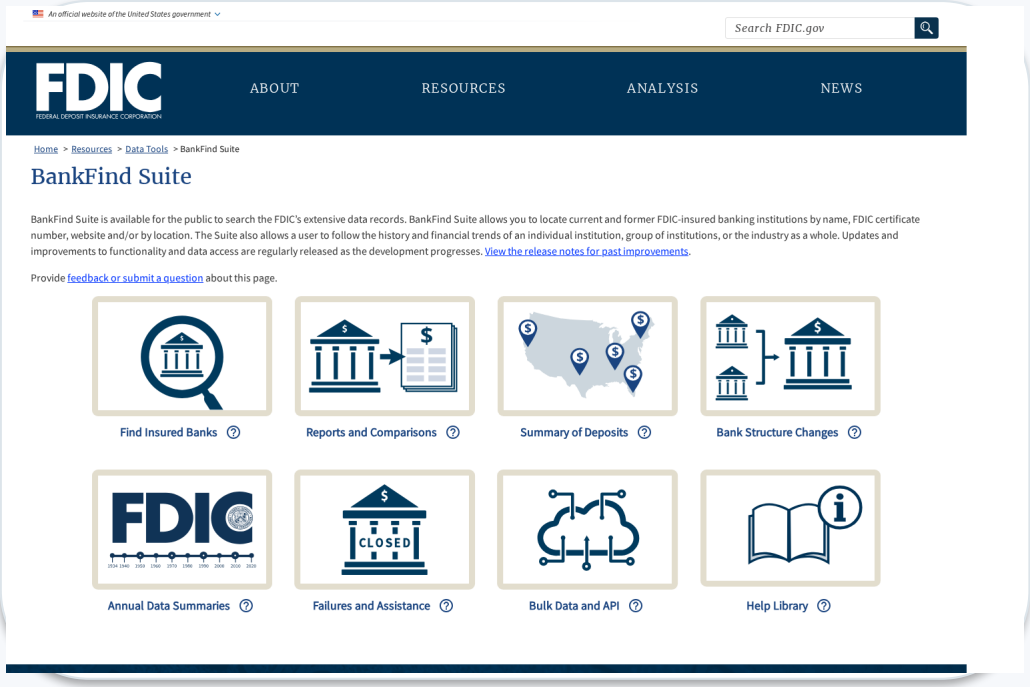
Decider 6 次过早结束；没有 API 或浏览器动作错误来解释这些失败。

每任务最多 12 步、 150 秒；截图留证但不作为视觉输入。五任务各独立运行两次。

银行查询：停在入口页，与查到机构是两种结果

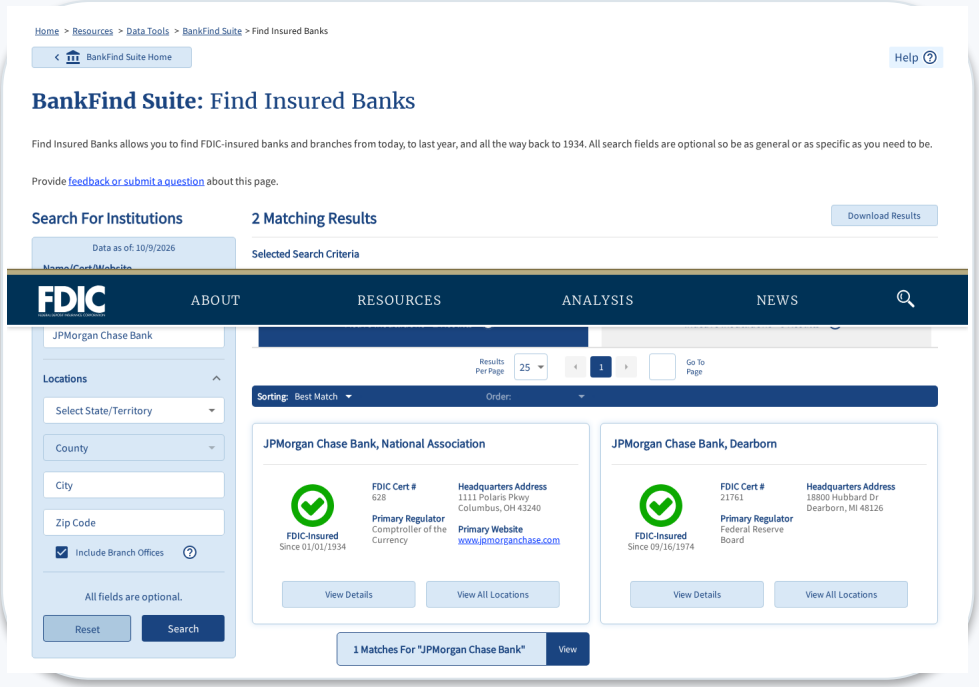
同一任务：查找 JPMorgan Chase Bank；截图来自第二轮真实浏览器终点。

Decider • 2 步后结束



返回 BankFind 入口，没有提交查询

Jev • 6 步完成



返回目标机构； FDIC Cert 628

原始页面截图仅裁切可读区域，完整图片与每步 URL / DOM / 动作保存在 validation/browser_finance 。

会分类，不代表能正确核验金额和条件

新闻、财报、存款保险、汇率业务； 30 道独立题，按原始候选顺序统计。

业务	Decider	Jev
财经新闻分类	11/12	11/12
财报证据核验	4/6	6/6
存款保险初筛	5/6	5/6
汇率报表 / 付款分流	2/6	6/6

共同错误：同银行、同类别的 18 万 + 12 万美元账户

两个模型都选“全部受保”；应合并为 30 万， 25 万受保、 5 万超限。

反转顺序后 Decider 24/30 、 Jev 28/30 ；仍是同一批 30 道题。

任务分流能做好，复合约束仍容易漏判

独立于网页四任务实验： 32 题 × 2 种顺序；自然语言对照只复测后 24 题。

题型	Decider 原始	Jev 原始	Decider 自然语言	Jev 自然语言
任务语义分流	16/16	15/16	—	—
能力 / 上下文	3/16	7/16	2/16	7/16
成本 / 预算	2/16	9/16	2/16	9/16
可用性 / 回退	4/16	15/16	4/16	15/16

复合政策合计 **Decider 9/48 → 8/48** **Jev 31/48 → 31/48**

把候选改成自然语言，没有修复多约束比较； Decider 在自然语言批次全部选择 no_route 。

能力 / 价格来自 OpenRouter 目录，健康 / 延迟等为题设；未调用 openrouter/auto 或下游模型。

俄罗斯方块：改写候选，也未消除动作差距

独立项目记录：同一 seed 42 ，每局最多 50 块；主比较全部由模型选择落点。

候选表达	Decider	Jev
数字字段	36 块 / 0 行	50 块 / 19 行
自然语言	43 块 / 2 行	50 块 / 19 行

固定棋盘诊断

Decider： 数字版 3/3 次选较差动作。

Jev： 两种表达均 0/3 。

游戏结论：本局优先 Jev

自然语言版： 251.1 vs 1414.5 ms/ 落点。

适合继续验证动作选择；仅测一个种子。

落点耗时为 Jev / Decider 均值，可含多次请求。游戏未保存 token usage ，费用不作估算。

Jev： 证据核验和多步操作表现更好，复杂规则仍需复核

本批业务效果更好；延迟并非每项领先。按实际输入，每千次 Jev API 约 $0.02–0.08 。

测试场景	业务结果 Jev / Decider	Jev ms	Decider ms	Jev $/ 千次	适用结论
Skills	65/65 · 50/65	119.9	164.6	$0.021	证据核验： Jev 优先
真实浏览器	10/10 · 4/10	137.0	227.3	$0.080	多步查找： Jev 优先
金融初筛	28/30 · 22/30	138.3	97.4	$0.031	初筛可用；金额用代码
政策路由	46/64 · 25/64	137.4	211.4	$0.061	任务分流；约束用代码

Jev 可优先试点证据核验与多步操作；金额、资格、预算和最终完成条件，仍由程序独立验收。

API RTT 中位数： Jev 直连， Decider 经应用网关；金融仅首轮。费用按实测 usage ，不含工具与运维。

先讲清条件适用范围，20 个节点改善了 4 个

支付实验：权重未变，只改输入与候选说明；参考一致次数 14/20 → 18/20 。

优化前

地址是否验证?
审批是否通过?

条件混在一起，
非退款也可能被拦截。

优化后

先确定 case_type 。
仅 refund 检查退款地址。

省略字段表示“不适用”。
审批通过不等于到账。

程序先计算金额差、确认是否足够等事实；模型在适用的业务条件中选择下一步。

2026-10-11 优化对照； 20 个节点使用相同演示参考，未进行模型微调。

把失败样本留下，再决定是否需要微调

按业务拆开语义判断与确定性检查，让模型负责它能可靠完成的部分。

冻结回归集

缺证据 / 早结束 / 错算

拆清业务条件

金额、预算、能力用代码校验

再做领域训练

LoRA / 决策头，加入困难反例

独立验收上线

完成度、校准、拒绝与回退

浏览器 / 支付

finish 前核验页面、产物或账本；缺证据继续收集。

模型路由

语义分流交给模型；硬约束筛选后再排序和回退。

下列为后续方案；尚未完成领域微调，也未宣称新的准确率或生产收益。

保留决策头，把单请求执行接到并发调度

这不是把 Decider 当聊天模型生成 JSON；适配使用官方模板、位置元数据与评分逻辑。

导出权重

合并 LoRA，保存决策头

→

校验产物

模板 / 分词器 / 校准参数

→

启动 API

定制 Pooler + 并发调度

→

对齐原版

choice 与数值分别验收

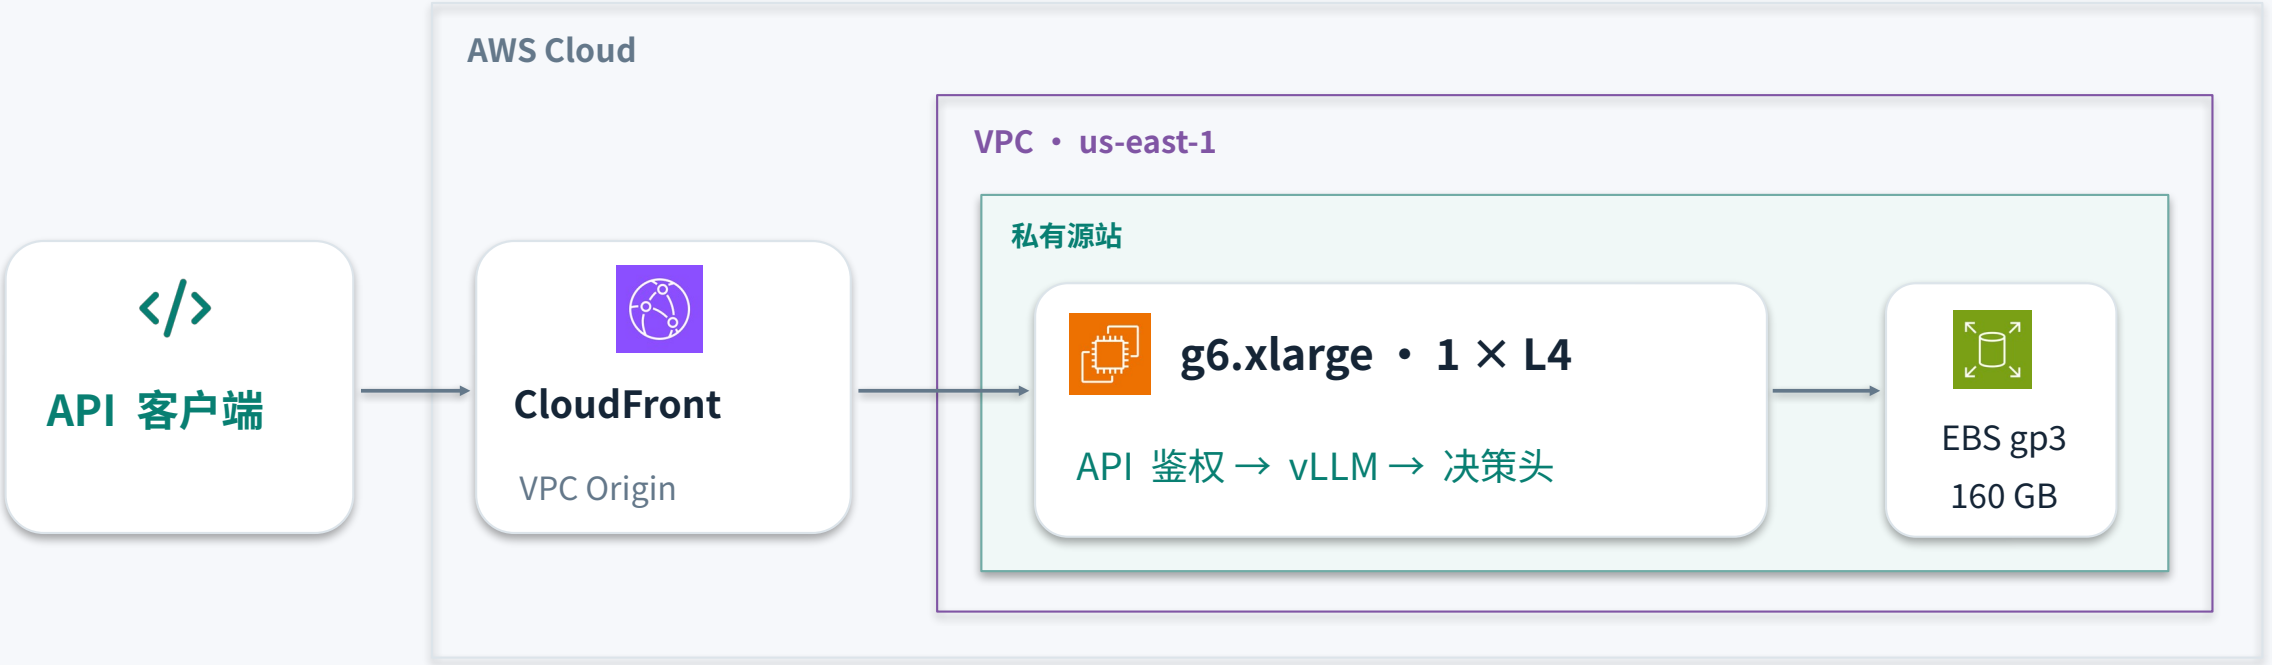
decider-vllm export → verify-artifacts → serve

serve --max-num-seqs 128 --max-num-batched-tokens 8192

vLLM 0.31.0； BF16 底座 / FP32 Pointer Head；未开启前缀缓存、分块预填充或 CUDA Graph。

公网 API，私网 EC2 源站，模型持续驻留

独立 StrandsDeciderVLLM 项目： g6.xlarge / 1 × NVIDIA L4；与主演示的原版实例分开。

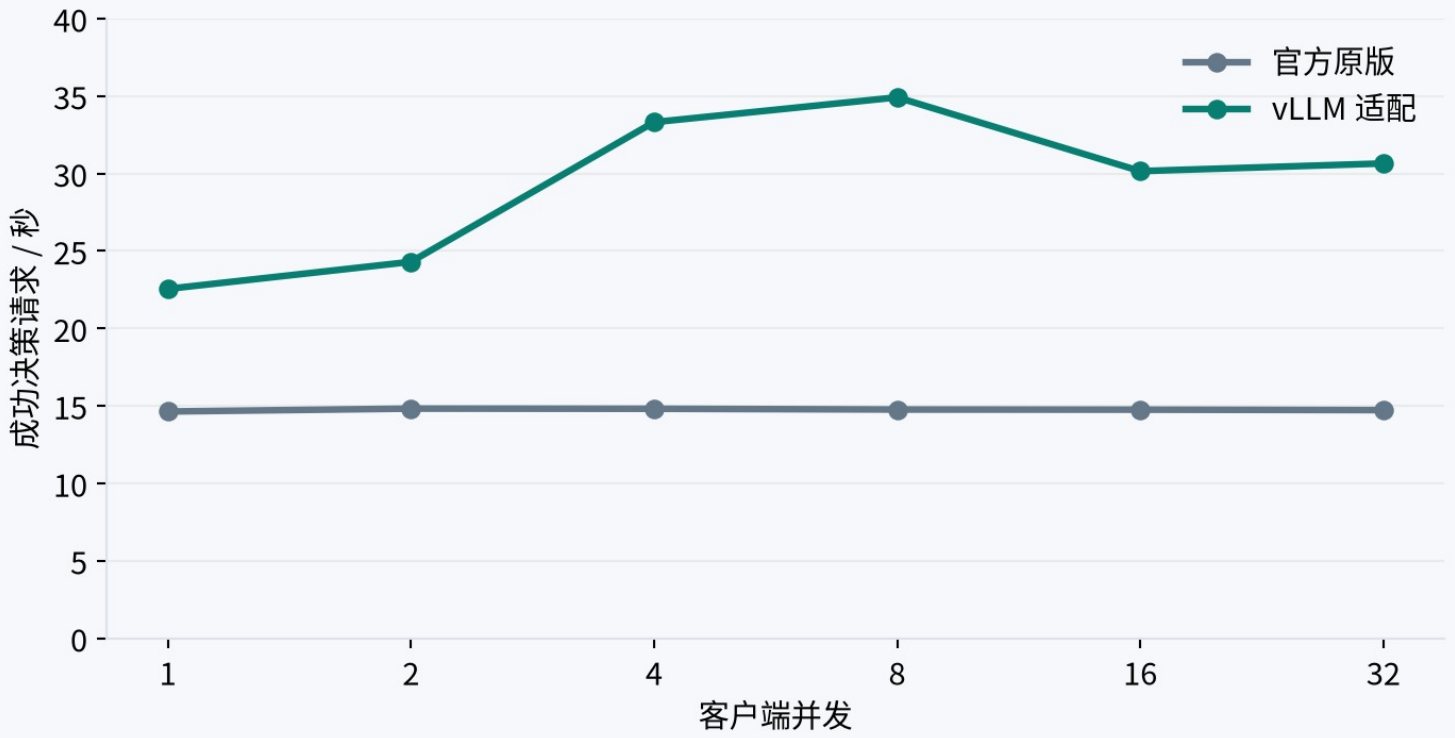


压测：固定 worker，完整响应后补发；每档预热另计、失败不重试。吞吐按成功请求 / 总时长计算。

API 使用访问密钥； CloudFront VPC Origin 。图中省略网络端点，后端直接调用相关 AWS 服务。

同一块 L4 ， 8 并发吞吐提升约 2.36 倍

同机实验： g6.4xlarge ，两个容器均限制 4 vCPU / 14 GiB ；回环 HTTP 。



14.76 → 34.91

成功请求 / 秒

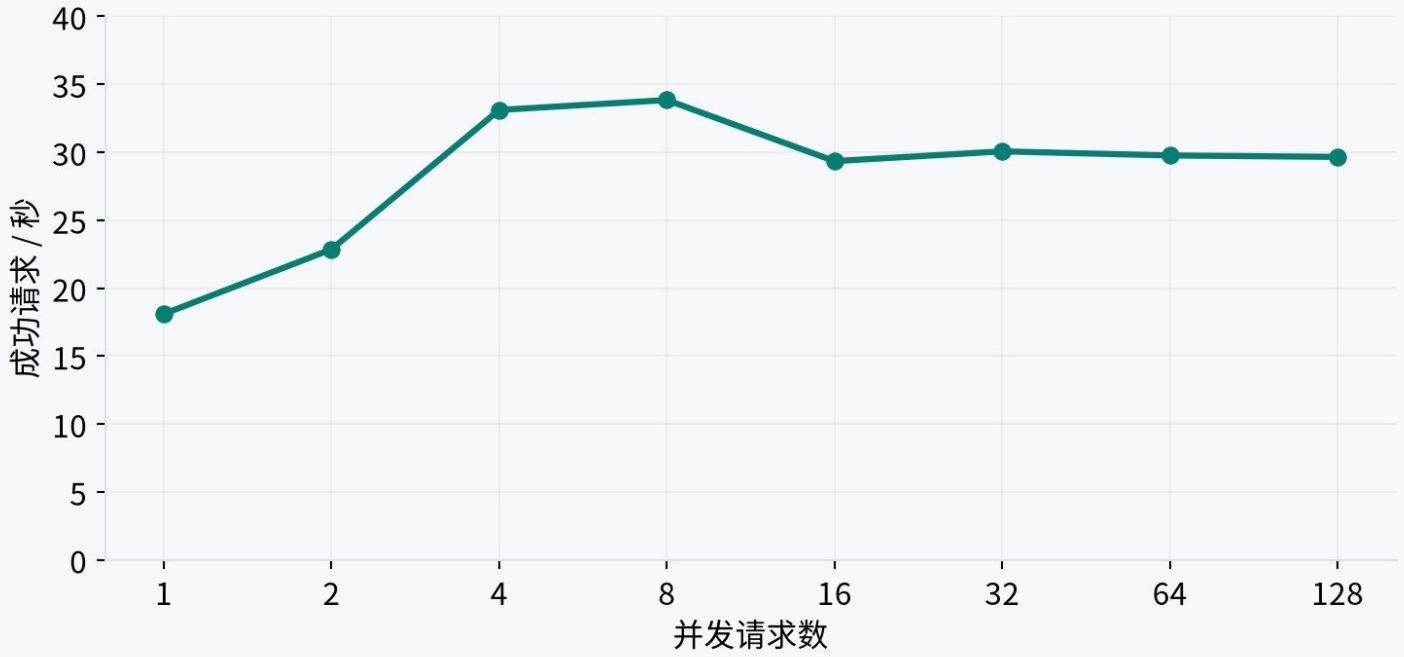
542.8 → 237.6

P95 毫秒 · 8 并发

每档 80 请求，预热另计。提升同时包含推理路径和调度变化，不能全部归因于批处理。

超过 8 并发后，这批短输入主要在增加等待

g6.xlarge 公网 API； 1–128 并发每档 1,280 请求。输入 304–445 token，均值 373.9。



并发	吞吐 / s	P95 ms
8	33.84	245.0
128	29.65	4986.1

更大的 token 预算
未提高这批短输入吞吐。
先找服务容量，再设排队上限。

batch 参数是调度 token 预算，不是请求数。 8192 / 16384 / 32768 合计 23,040 次均成功。

低并发 Decider 延迟低， Jev 在中并发吞吐更高

相同 20 个支付输入循环提交； Decider 8192 token 预算； Jev 直连 API 。

并发	Decider 请求 /s	Jev 请求 /s	Decider P95	Jev P95
1	18.01	7.90	59.4	160.2
8	35.74	61.83	237.0	166.9
32	30.61	240.94	1073.1	172.6
128	30.59	52.56	11236.8	5502.5

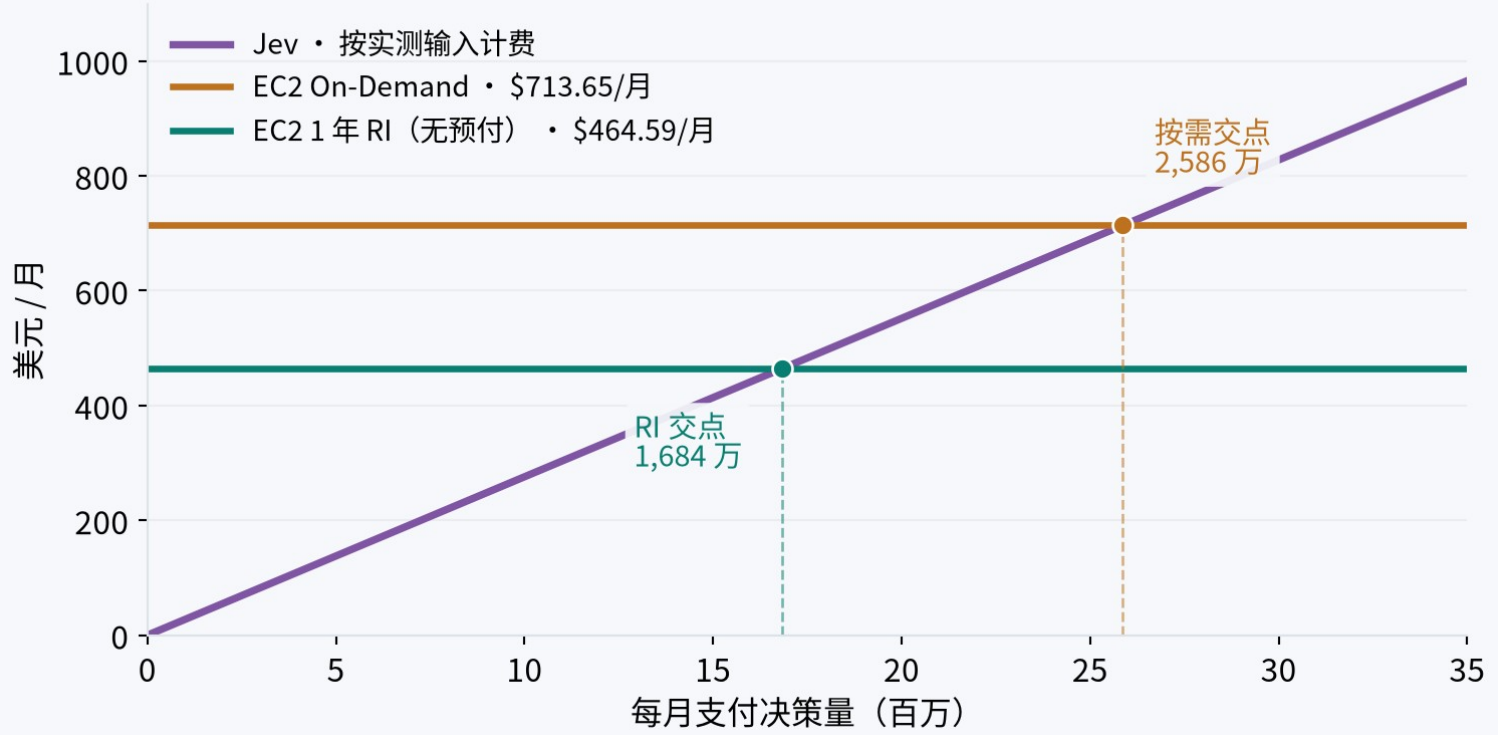
Decider： 10,239/10,240 成功， 1 次 502 ； 10 次置信度差异略超数值对齐容差。

Jev： 10,240/10,240 成功； 128 并发的吞吐回落，尾延迟也明显增加。

2026-10-13 ，每模型 10,240 次正式尝试； P95 为成功响应端到端延迟，单位毫秒。

支付单次： 1 年 RI 的交点约 1684 万次 / 月

三条曲线： EC2 On-Demand 、 1 年 Standard RI （无预付）、 Jev 按输入用量计费。



1 年 RI 交点

约 1,684 万次 / 月

On-Demand 交点

约 2,586 万次 / 月

平均 656.95 输入 token / 次

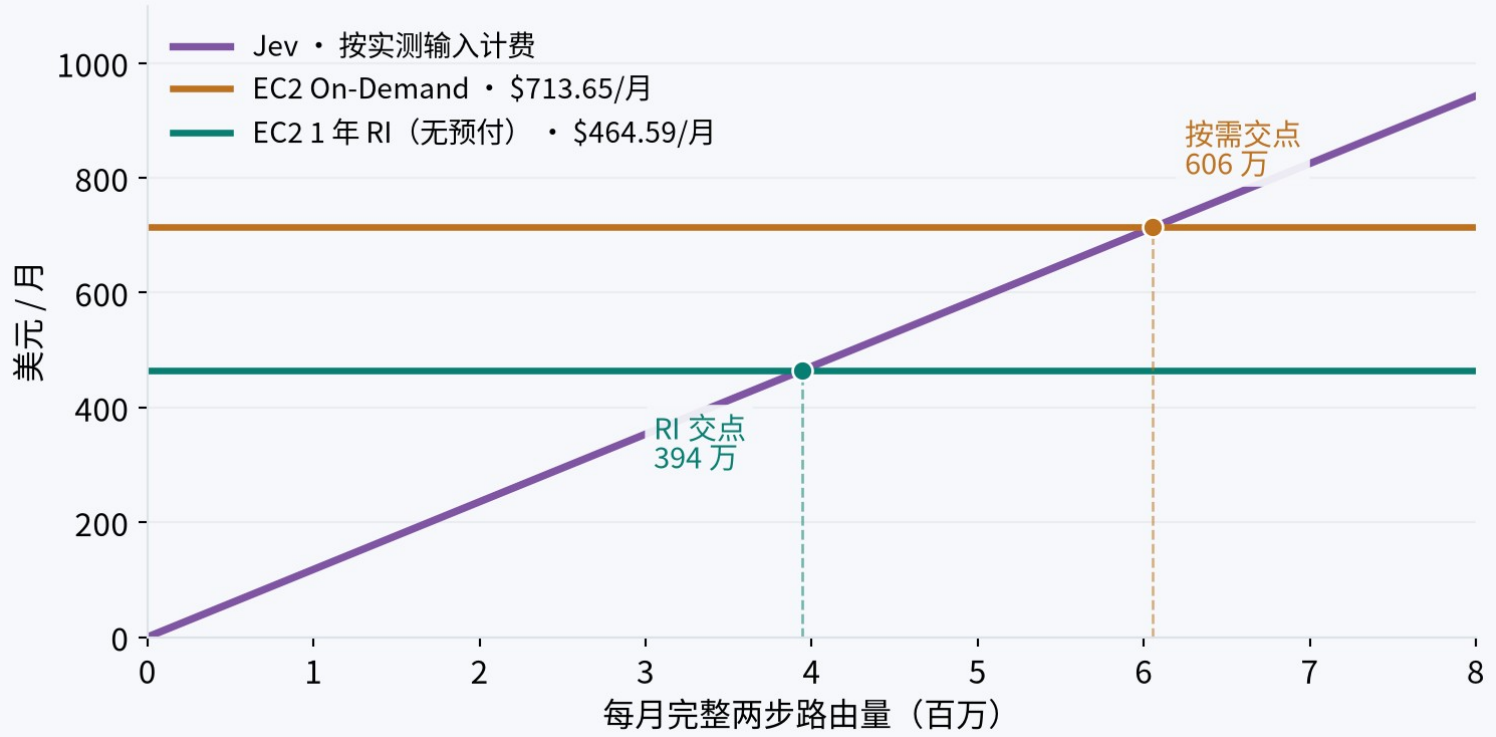
Jev： $27.59 / 百万次

单台可承载时：低于 RI 交点， Jev 最省；两交点之间 RI 最省， Jev 仍比按需低；再增量，两种 EC2 都更低。

g6.2xlarge · us-east-1 · 730h/ 月；只比计算 /API 费用，容量与质量另验。 RI 闲置仍计费，其他资源费用另计。

两步模型路由： 1 年 RI 的交点约 394 万条 / 月

一次完整路由包含“选流程 + 选型号”两次判断；输入更长， Jev 费用曲线也更陡。



1 年 RI 交点

约 394 万条 / 月

On-Demand 交点

约 606 万条 / 月

平均 2,805.75 输入 token / 条

Jev： $117.84 / 百万条

单台可承载时：低于 RI 交点， Jev 最省；两交点之间 RI 最省， Jev 仍比按需低；再增量，两种 EC2 都更低。

g6.2xlarge · us-east-1 · 730h/ 月；只比计算 /API 费用，容量与质量另验。 RI 闲置仍计费，其他资源费用另计。

业务质量先过关，再在低延迟、自托管与按量之间选择

同一支付批次： Decider 102.2 ms / 18/20 ； Jev 416.5 ms / 20/20 ； GPT 1116.7 ms / 20/20 。

Decider： 高频选择

优先：分类、工具选择、分流。

低单次延迟、可控自托管。
稳定流量再评估 1 年 RI 。
证据与完成判断需补强。

Jev： 证据与多步操作

优先：核验、文字浏览器操作。

低或波动流量，按量付费。
本批业务效果更好。
金额与路由硬约束仍复核。

GPT： 开放式复杂任务

适合：回复、代码、复杂异常。

本次支付参考一致 20/20 。
高频短选择要权衡延迟。
开放任务质量需单独实测。

支付为平均后端耗时与参考一致次数；小样本。公共 vLLM 延迟与验证场景的 RTT 分开统计。

打开演示，查看真实过程和原始记录

演示展示输入、原始选择、实际动作和结果；仓库保留验证脚本、截图与数据。

在线演示	https://d3i7ogfx5ml7dc.cloudfront.net
主项目	https://github.com/milan9527/StrandsDecider
vLLM 适配与公共 API	https://github.com/milan9527/StrandsDeciderVLLM
场景验证结果与截图	https://github.com/milan9527/StrandsDecider/blob/main/validation/README.md
Strands Decider 官方介绍	https://strandsagents.com/blog/introducing-strands-decider/
JevBench 评测结果与方法	https://benchmarkheaven.com/jev-models/api

PPT 内含逐页讲稿与来源； v11 聚焦 Jev 场景结论、按需与 1 年 RI 成本交叉图。