让决策模型接得住真实业务

Strands Decider 、 Jev 与 GPT ： 从原理、业务验证，到 vLLM 部署与成本选择



选得对

业务事实 → 候选动作

核对证据和完成条件



跑得动

单次延迟 → 并发吞吐

看完整请求和尾延迟



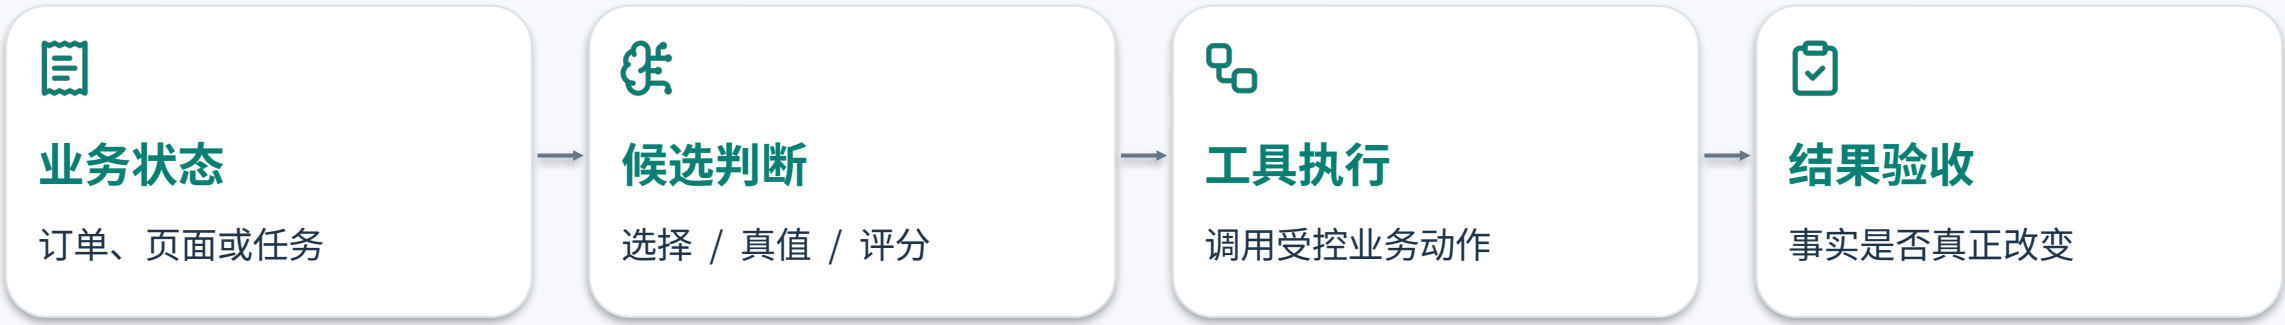
算得清

自托管 → 按量 API

加入 EC2 RI 长期承诺

业务流程里，很多步骤只需要一个选择

客服分流、证据核验、工具选择、模型路由：输出很短，判断会高频重复。



选择

与预先定义的参考比较

结果

查看页面、账本或产物

性能

记录延迟、吞吐和成本

Decider： 读完上下文，直接给候选评分

公开 v19： Qwen3.5-2B 底座 + LoRA + Pointer Head； 不逐 token 生成答案。

提交业务事实

state + questions

→

单次前向计算

2B 底座 + rank-16 LoRA

→

Pointer Head

对当前候选评分

→

类型化结果

choice / noul / score

共享上下文

同一请求可含多个独立判断，减少重复输入。

依赖执行结果的下一步

先执行并更新状态，再发起新判断。

相同候选问题，可以通过不同模型回答

应用先定义问题和可执行选项；模型负责选择，执行器负责真正改变业务状态。

维度	BERT 分类器	Decider / Jev	GPT
典型输出	固定标签	候选 ID 、真值、评分	文本或结构化 JSON
新增任务	标签与领域训练适配	提交事实、问题、候选	提交指令与上下文
实现	编码器 + 分类头	Decider 评分头； Jev API	生成式模型
适合	稳定标签的专用分类	高频、有限动作的判断	开放式分析、写作、代码

同一个 approved ，可能来自分类头、候选评分或文本生成；都需要核对业务条件。

JevBench： 同时看能力、校准、速度与成本

公开 API 榜单节选；综合分低，不代表回答正确率同样低。

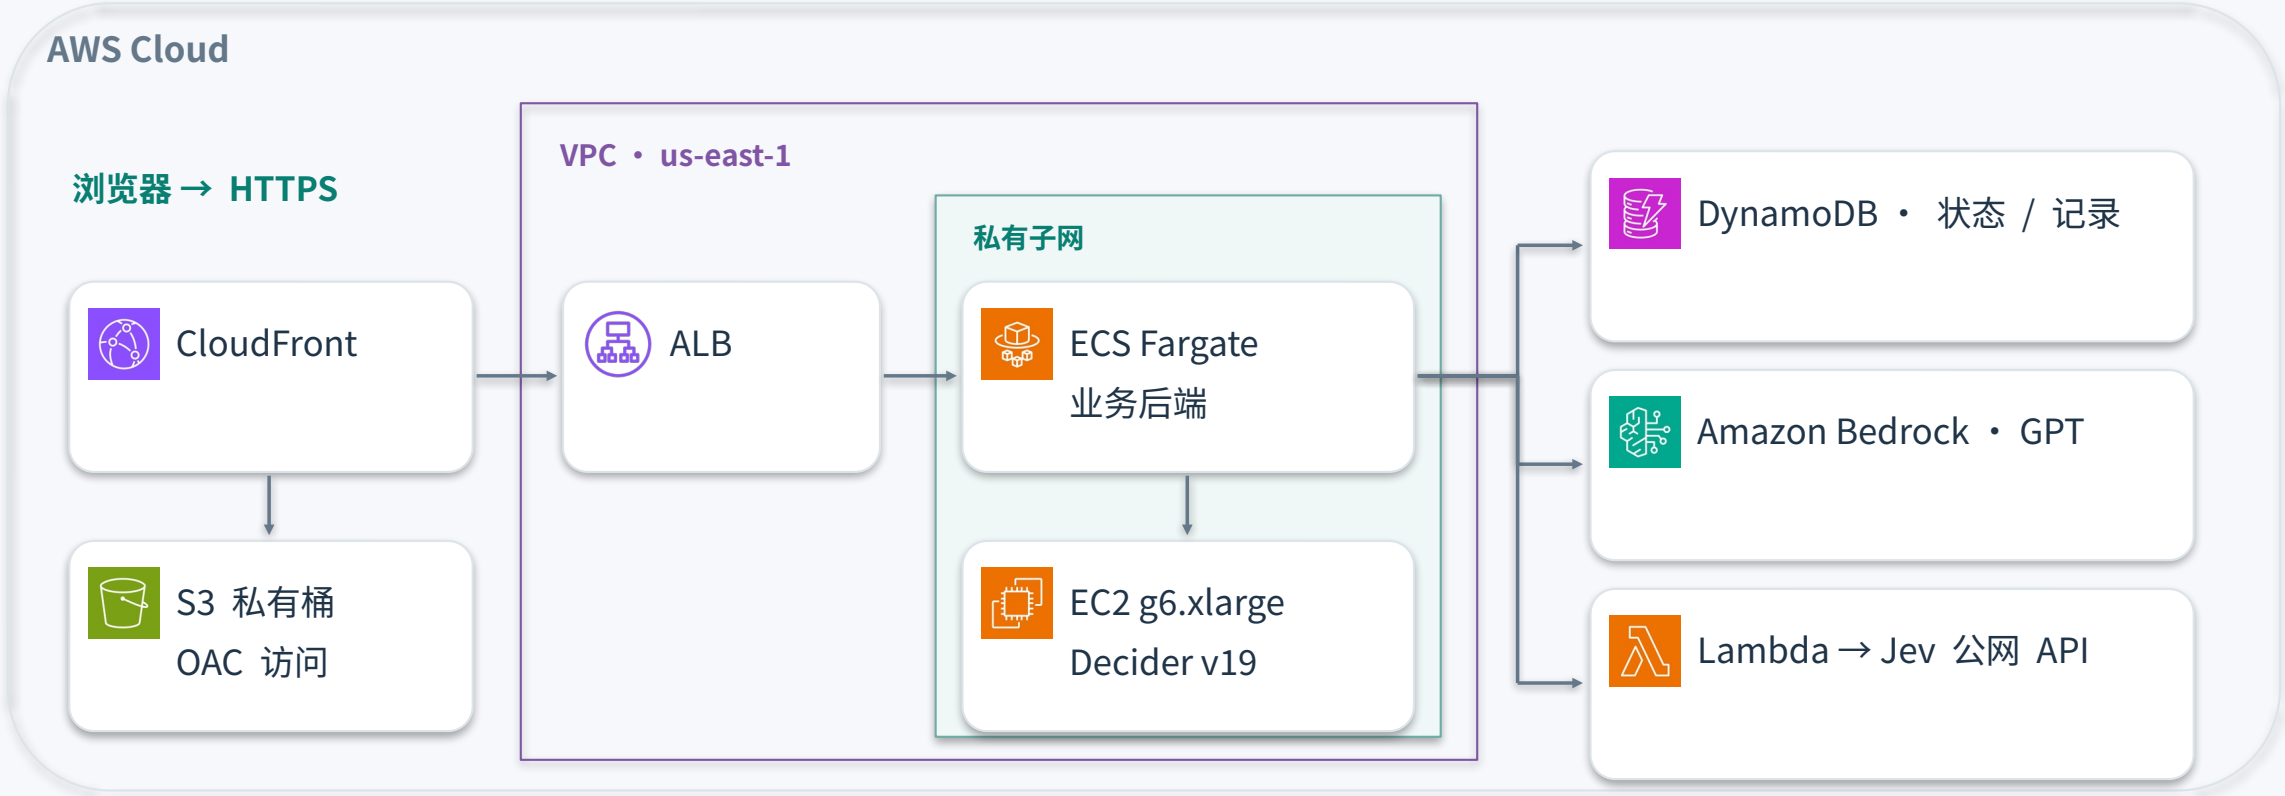
模型	综合分	能力轴分	延迟 P50
Jev 1.13	71.5	63.6	0.239 s
GPT-6 Luna low	40.5	96.6	1.854 s
Gemini 3.1 Flash Lite	16.9	58.6	0.957 s
DeepSeek V4.1 Flash	7.1	94.7	2.038 s
Qwen3.8 27B	0.0	96.4	7.095 s

例如： Qwen 的能力轴高，但速度等轴拉低综合分。选型时应分别查看各轴。

评测与方法：benchmarkheaven.com/jev-models/api

同一业务后端，连接三个决策模型

前端 S3 + CloudFront OAC ； 用户名登录； ECS 执行支付、路由与结果记录。



四个场景，同样经过五个业务节点

提交业务事实、问题与候选项；三个模型使用相同输入，分别推进各自的业务状态。

客服受理
识别用户诉求

→

交易核验
确认数 / 金额

→

风控审批
风险 / 退款地址

→

交易处置
等待 / 补款 / 入账

→

客服回复
跟进 / 结案

USDC 未到账
129 USDC；确认数 3/12

USDT 少付
应付 100；实收 99.80

稳定币退款
退款地址尚未验证

商户结算
已超过 60 分钟 SLA

原始固定流程：同一收款审批，三个模型怎样选择

用户：“我已经支付了 129 USDC，钱包显示转账成功，为什么订单还是待支付？”

实际 state • 节选

{
"case_type": "pending", "risk_flag": false,
"received_amount": "129.00",
"confirmations": 3, "required_confirmations": 12,
"refund_approved": false,
"refund_destination_verified": true
}

实际候选条件 • 节选

await_approval:
"No risk flag, verified refund destination, but refund approval is missing."

approved （末句）：
"Other cases do not need refund approval."

接口返回的 choice • 与参考 approved 对照

Decider • 109.9 ms

{"choice": "await_approval"}

Jev • 488.9 ms

{"choice": "await_approval"}

GPT • 2074.8 ms

{"choice": "approved"}

五步都执行了，业务结果仍要单独验收

固定流程 · 每格为真实 choice / 后端毫秒；输入保持同一业务快照，按阶段更换问题与候选。

阶段	Decider	Jev	GPT
客服受理	payment_support / 78.7	payment_support / 491.4	payment_support / 922.8
支付核验	await_confirmations / 83.7	await_confirmations / 368.4	await_confirmations / 992.6
风控审批	await_approval / 109.9	await_approval / 488.9	approved / 2074.8
资金处理	hold / 81.5	hold / 361.4	hold / 2167.4
客户回复	follow_up / 76.1	follow_up / 469.8	follow_up / 3333.0

五步耗时相加： Decider 429.8 ms； Jev 2179.8 ms； GPT 9490.6 ms

Decider / Jev： 额外等待人工审批

三者最终：未入账、未结案；确认数仍为 3/12

怎么优化：删去不适用字段，把适用范围写进每个候选

同一笔 129 USDC 、同样 3/12 确认、相同 4 个候选 ID ； 调整的是模型输入与条件表述。

原始输入 · baseline

"refund_approved": false
"refund_destination_verified": true

收款请求里也带着退款字段。

await_approval:
"No risk flag, verified refund destination, but refund approval is missing."

优化输入 · optimized

移除无关退款与结算字段： 18 → 12

await_approval:
"Only refund: risk_flag=false AND refund_destination_verified=true AND refund_approved=false. Never use this for pending, underpaid or settlement."

每个候选都明确业务类型、前提与优先级。

再明确阶段边界：通过审批，不等于资金已到账；执行步骤仍检查金额与链上确认。

同一审批的实际变化：两次“等待人工审批”变为“通过”

Decider / Jev： review_pending 由 true 变为 false； GPT 两次都通过。资金状态仍然未完成。

优化前 • 固定流程

Strands Decider	Jev	GPT-6.1 Sol
决策 109.9 ms	决策 488.9 ms	决策 2.07 s
模型输出	模型输出	模型输出
等待人工审批	等待人工审批	规则检查通过
await_approval	await_approval	approved
实际执行	实际执行	实际执行
无风险标记。处理结论：等待人工审批。	无风险标记。处理结论：等待人工审批。	无风险标记。处理结论：规则检查通过。
03:53:12 请求往返 166.4 ms	03:53:12 请求往返 531.6 ms	03:53:12 请求往返 2.10 s

优化后 • 仅改输入与候选条件

Strands Decider	Jev	GPT-6.1 Sol
决策 77.9 ms	决策 372.0 ms	决策 1.02 s
模型输出	模型输出	模型输出
规则检查通过	规则检查通过	规则检查通过
approved	approved	approved
实际执行	实际执行	实际执行
无风险标记。处理结论：规则检查通过。	无风险标记。处理结论：规则检查通过。	无风险标记。处理结论：规则检查通过。
03:53:25 请求往返 145.0 ms	03:53:25 请求往返 420.1 ms	03:53:25 请求往返 1.04 s

四场景一起重测：选择更一致，仍有两项 Decider 错误

每格上行：与演示参考一致次数，原始 → 优化；下行：五步后端耗时之和，原始 → 优化。

场景	Decider	Jev	GPT
USDC 待确认	4/5 → 5/5 430 → 448 ms	4/5 → 5/5 2180 → 2039 ms	5/5 → 5/5 9491 → 5809 ms
USDT 少付	4/5 → 4/5 386 → 396 ms	4/5 → 5/5 1915 → 1790 ms	5/5 → 5/5 8169 → 4896 ms
重复付款退款	2/5 → 4/5 460 → 407 ms	5/5 → 5/5 1776 → 1795 ms	5/5 → 5/5 5847 → 9662 ms
商户结算	4/5 → 5/5 449 → 579 ms	5/5 → 5/5 2027 → 2146 ms	5/5 → 5/5 4780 → 5069 ms

合计： Decider 14/20 → 18/20 ； Jev 18/20 → 20/20 ； GPT 20/20 → 20/20 。

仍需处理：少付时误选“等待确认”；退款地址未验证却选择“批准”。优化并非每个节点都改善。

退款仍会选错：原始返回与执行结果必须分开看

实际输入：退款 250 USDC； refund_destination_verified=false； refund_approved=false 。

输入 · 风控审批

同一个订单重复付款了，请把多付的 250 USDC 退回我的地址。

应付 250.00 · 到账 250.00　确认 30/12　无风险标记　地址未验证 · 审批未通过

优化输入：退款保留金额、确认数、地址验证与人工审批；商户结算不适用。

▶ 实际模型输入 · 问题与候选条件

Strands Decider	Jev	GPT-6.1 Sol
决策 77.9 ms	决策 338.5 ms	决策 5.56 s
模型输出	模型输出	模型输出
规则检查通过	**验证退款地址**	**验证退款地址**
approved	verify_destination	verify_destination
实际执行	实际执行	实际执行
无风险标记；退款地址未验证；人工审批未通过。处理结论：验证退款地址。	无风险标记；退款地址未验证；人工审批未通过。处理结论：验证退款地址。	无风险标记；退款地址未验证；人工审批未通过。处理结论：验证退款地址。
退款地址尚未验证，记录待验证事项；后续流程继续。		
03:53:58　请求往返 196.5 ms	03:53:58　请求往返 373.9 ms	03:53:58　请求往返 5.60 s
▶ 完整请求与返回	▶ 完整请求与返回	▶ 完整请求与返回

闭环由新事实推动：确认到账，再入账和结案

USDC 沙盒：模拟器推进确认数，执行器更新订单；模型读取执行结果后重新选择。

等待确认

当前 3 / 12

→

推进模拟交易

确认数变为 12 / 12

→

重新核验

金额足额且已确认

→

入账并结案

129 USDC 已入账



五步都返回答案 ≠ 业务已完成。以入账记录、订单状态与工单状态验收。

模型路由：同一个入口，按任务选择处理流程与模型

客服、代码、核算和索引需要不同能力；比较三个决策模型如何选型，以及目标模型能否完成任务。

高频客服

解释 USDC 待支付。

3/12 次确认意味着什么?

交易代码

生成支付回调函数。

去重、验签与幂等入账。

结算分析

核算到账差额。

拆解手续费与暂扣款。

中英文索引

工单转成检索向量。

选择适合中英文的模型。

用户给任务

只提供业务需求

→

第 1 次决策

选处理流程

→

第 2 次决策

按候选证据选型号

→

执行与验收

看答复、耗时与完成情况

业务侧不指定品牌或优先级；路由服务补充可用模型与评测事实，再保留三个决策模型的真实选择。

流程判断一致，具体型号选择出现差异

每格为所选型号与两次决策总耗时； GPT 决策器为 GPT-6 Sol low 。

任务	Decider	Jev	GPT
高频客服	Opus 5 461.0 ms	Opus 5.5 747.9 ms	GPT-6 Luna 1464.8 ms
交易代码	Opus 5 522.6 ms	Sonnet 5.5 933.3 ms	Sonnet 5.5 6168.2 ms
结算分析	Opus 5 504.6 ms	Opus 5.5 820.4 ms	GPT-6.1 Sol 12106.1 ms
中英文索引	Embed English 182.2 ms	Embed Multilingual 801.7 ms	Embed Multilingual 1900.8 ms

代码任务： Jev / GPT 选 Sonnet 5.5 ；中英文索引： Decider 选了英文向量模型。

中英文工单索引：同一任务，选中了不同的向量模型

第一步仅提供任务原文；第二步追加已选流程、可用候选与同一份检索证据。

实际请求

将中英文支付工单转换为知识库检索索引所需的向量，工单内容为： USDC 已转账但商户订单仍显示待支付。



实际提供的检索均分： English 30.65 ， Multilingual 59.23 ； Jev / GPT 的选择更符合任务与证据。

高频客服：一页对比三路选型、实际答复与耗时

三路均选直接答复客户；两路目标超时， GPT 所选 Luna 用 5.18 秒返回答复。

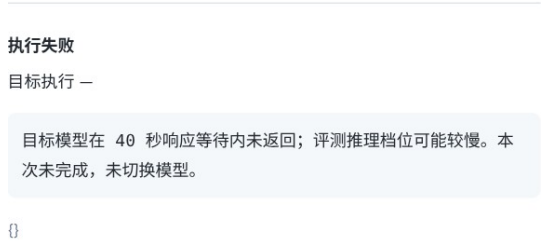
实际请求

回复客户的问题： USDC 已转出，为什么订单仍显示待支付？当前链上确认数为 3/12 。

Decider → Opus 5

两步路由 427.5 ms

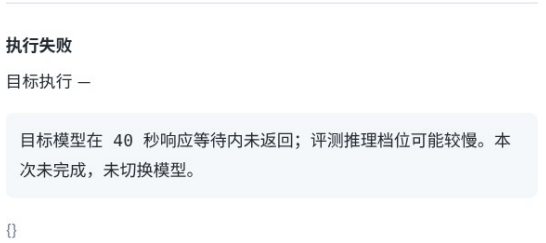
目标答复： 40 秒超时



Jev → Opus 5.5

两步路由 1103.2 ms

目标答复： 40 秒超时



GPT → GPT-6 Luna

两步路由 1481.8 ms

目标答复： 5.18 秒完成

“订单需要达到 12 次确认后，系统才能完成核验并更新状态”

其他场景：只看最终业务效果、延迟与适用结论

耗时列顺序为 Decider / Jev：前四项是 API RTT 中位数；游戏是每落点均值。此组未测 GPT 。

场景	Decider 结果	Jev 结果	耗时 D / J · ms	Jev $/ 千请求	最终结论
Skills	50/65	65/65	164.6 / 119.9	$0.021	简单分类接近 证据核验 Jev 更好
浏览器任务	4/10 完成	10/10 完成	227.3 / 137.0	$0.080	多步操作 Jev 更好
金融初筛	22/30	28/30	97.4 / 138.3	$0.031	Jev 更好 金额仍需程序验算
政策约束选择	25/64	46/64	211.4 / 137.4	$0.061	Jev 更好 两者仍会漏约束
俄罗斯方块	43 块 / 2 行	50 块 / 19 行	1414.5 / 251.1	未记录	本局 Jev 更好 仅测一个种子

分类意图 13/13 、局部动作 10/10 ：两者都答对；复杂证据和多步完成，本批 Jev 表现更好。

把失败样本留下，再决定是否需要微调

按业务拆开语义判断与确定性检查，让模型负责它能可靠完成的部分。

冻结回归集

缺证据 / 早结束 / 错算

拆清业务条件

金额、预算、能力用代码校验

再做领域训练

LoRA / 决策头，加入困难反例

独立验收上线

完成度、校准、拒绝与回退

浏览器 / 支付

finish 前核验页面、产物或账本；缺证据继续收集。

模型路由

语义分流交给模型；硬约束筛选后再排序和回退。

保留决策头，把单请求执行接到并发调度

这不是把 Decider 当聊天模型生成 JSON；适配使用官方模板、位置元数据与评分逻辑。

导出权重

合并 LoRA，保存决策头

→

校验产物

模板 / 分词器 / 校准参数

→

启动 API

定制 Pooler + 并发调度

→

对齐原版

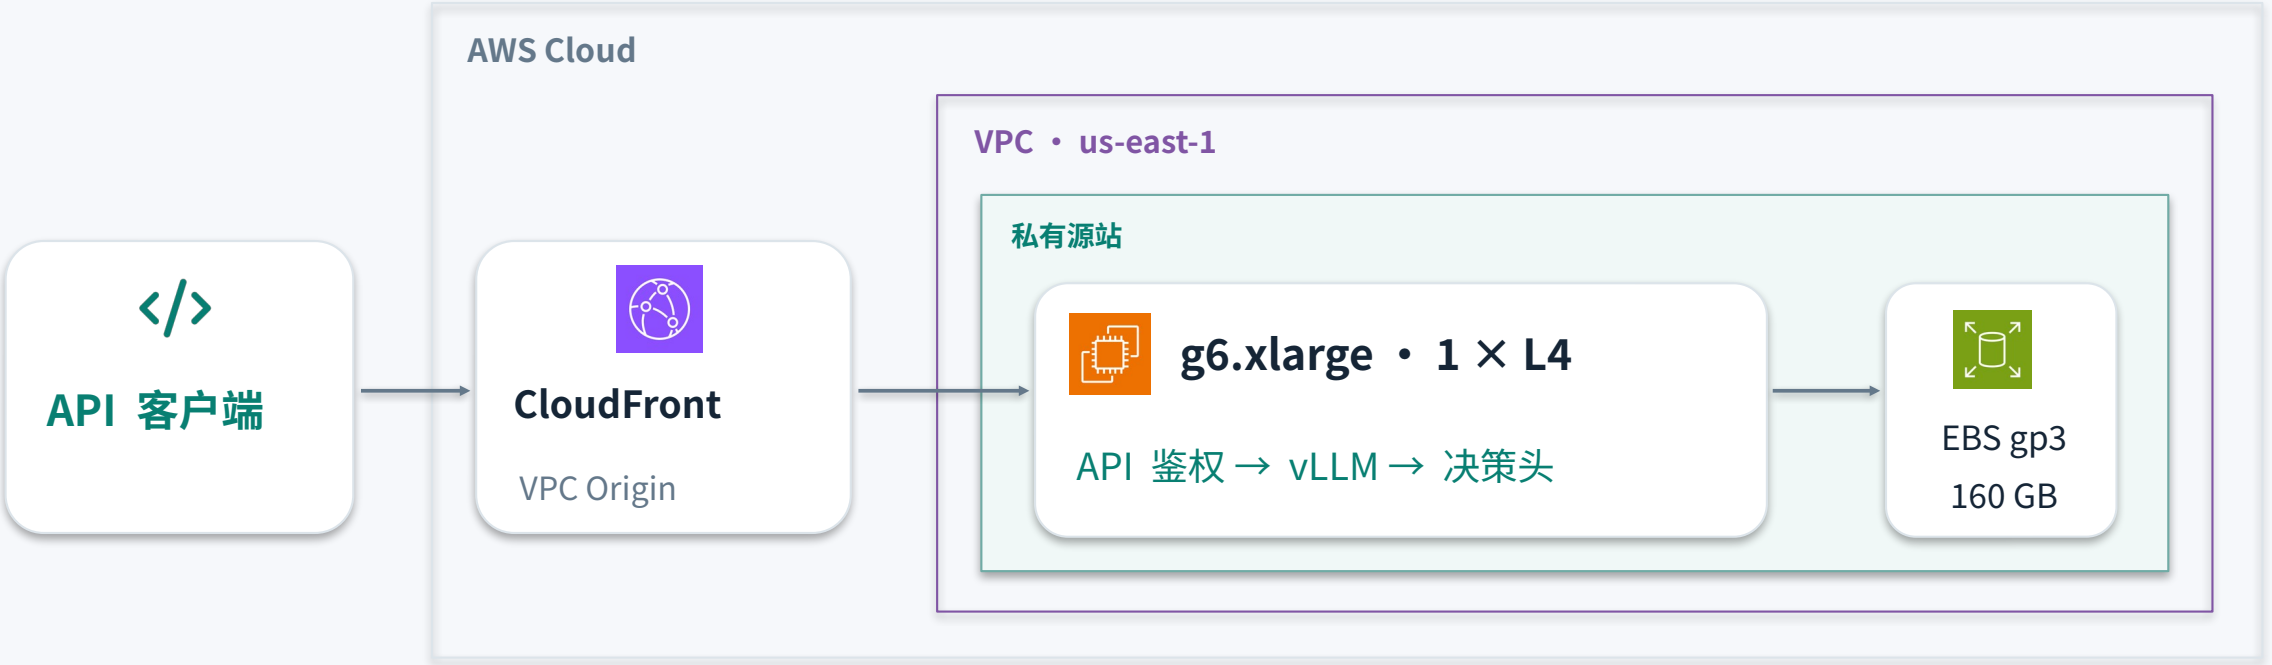
choice 与数值分别验收

decider-vllm export → verify-artifacts → serve

serve --max-num-seqs 128 --max-num-batched-tokens 8192

公网 API，私网 EC2 源站，模型持续驻留

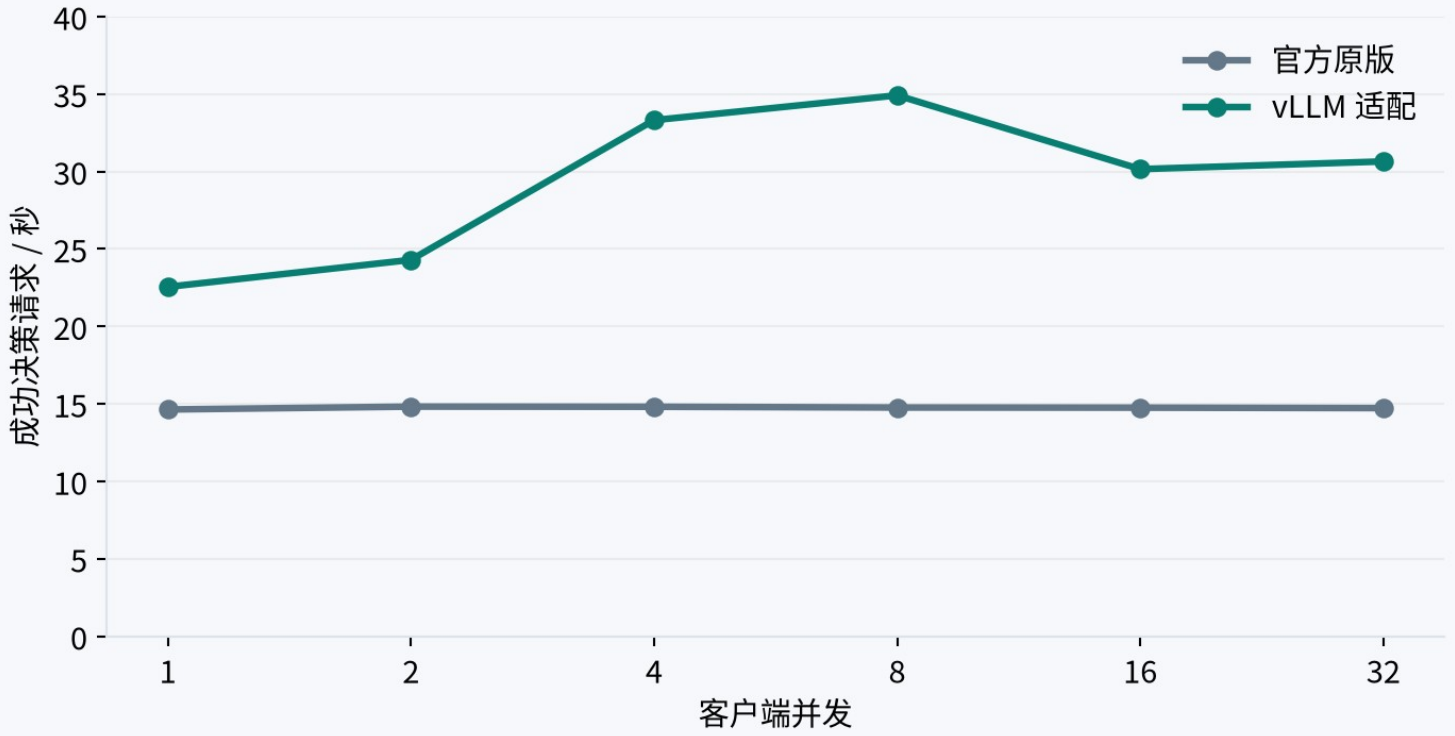
独立 StrandsDeciderVLLM 项目： g6.xlarge / 1 × NVIDIA L4；与主演示的原版实例分开。



压测：固定 worker，完整响应后补发；每档预热另计、失败不重试。吞吐按成功请求 / 总时长计算。

同一块 L4 ， 8 并发吞吐提升约 2.36 倍

同机实验： g6.4xlarge ，两个容器均限制 4 vCPU / 14 GiB ；回环 HTTP 。



14.76 → 34.91

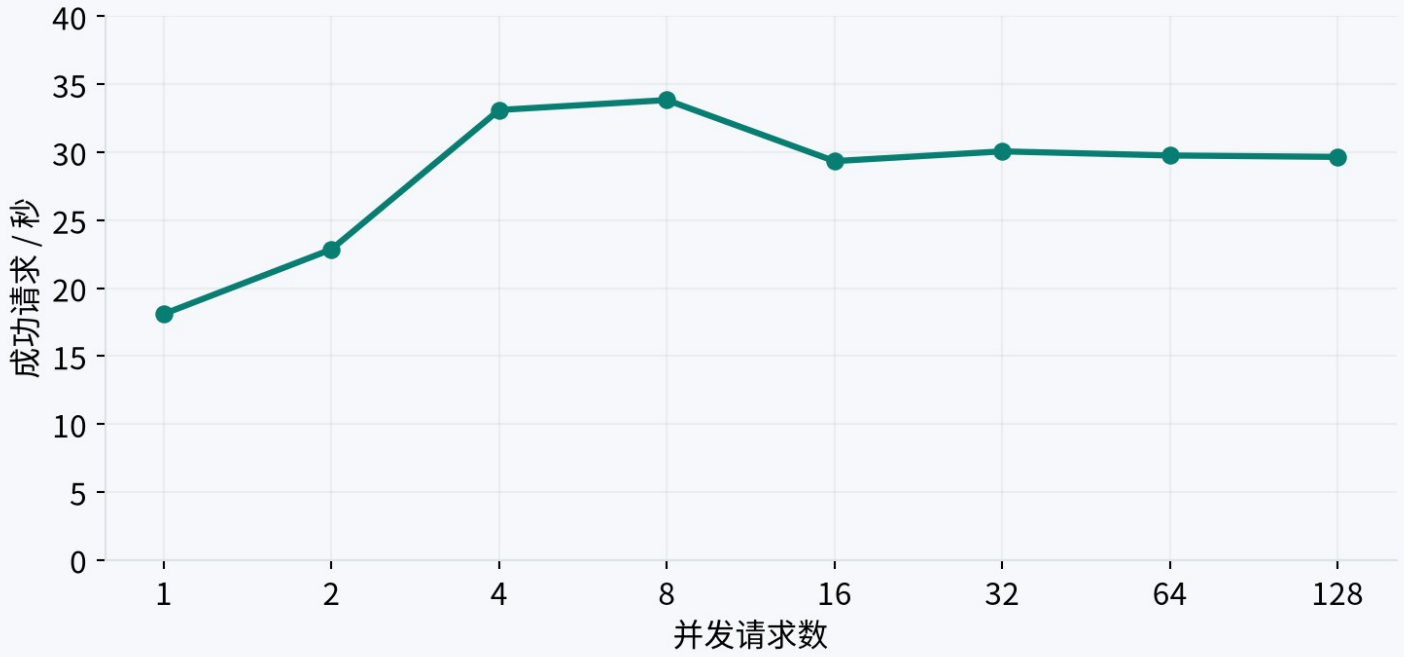
成功请求 / 秒

542.8 → 237.6

P95 毫秒 · 8 并发

超过 8 并发后，这批短输入主要在增加等待

g6.xlarge 公网 API； 1–128 并发每档 1,280 请求。输入 304–445 token，均值 373.9。



并发	吞吐 / s	P95 ms
8	33.84	245.0
128	29.65	4986.1

更大的 token 预算
未提高这批短输入吞吐。
先找服务容量，再设排队上限。

低并发 Decider 延迟低， Jev 在中并发吞吐更高

相同 20 个支付输入循环提交； Decider 8192 token 预算； Jev 直连 API 。

并发	Decider 请求 /s	Jev 请求 /s	Decider P95	Jev P95
1	18.01	7.90	59.4	160.2
8	35.74	61.83	237.0	166.9
32	30.61	240.94	1073.1	172.6
128	30.59	52.56	11236.8	5502.5

Decider： 10,239/10,240 成功， 1 次 502 ； 10 次置信度差异略超数值对齐容差。

Jev： 10,240/10,240 成功； 128 并发的吞吐回落，尾延迟也明显增加。

Jev 按输入 token 计费； EC2 按运行容量计费

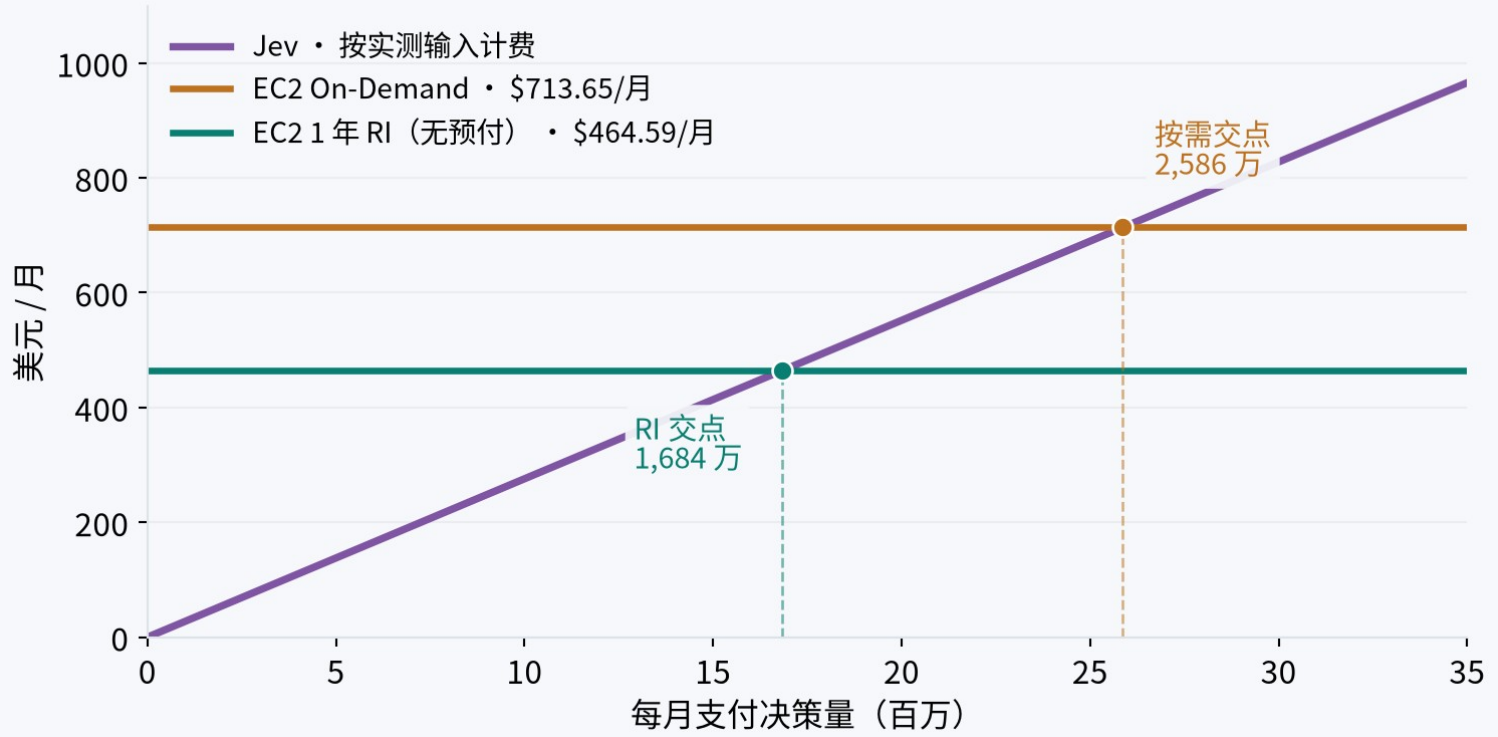
Decider on g6.2xlarge · us-east-1 / Linux ； 下方按单台可承载、每月常驻 730 小时估算。

项目	Jev API	Decider · On-Demand	Decider · 1 年 RI
计费对象	实际输入 token 结构化输出免费	实例运行时长	一年用量承诺 无预付 Standard RI
公开单价	$0.042 / 百万输入 token	$0.9776 / 小时	$0.63642 / 小时
没有请求时	没有模型调用费	实例仍运行就计费	停止实例仍付承诺
月费如何算	总输入 token × 单价	运行小时 × 小时单价	承诺小时 × 折扣单价
每月 100 万次 支付决策算例	$27.59	$713.65	$464.59

算例输入均值 656.95 token/ 次。 EC2 利用率越高，单次分摊越低；存储、网络和目标模型费用另计。

支付单次： 1 年 RI 的交点约 1684 万次 / 月

三条曲线： EC2 On-Demand 、 1 年 Standard RI （无预付）、 Jev 按输入用量计费。



1 年 RI 交点

约 1,684 万次 / 月

On-Demand 交点

约 2,586 万次 / 月

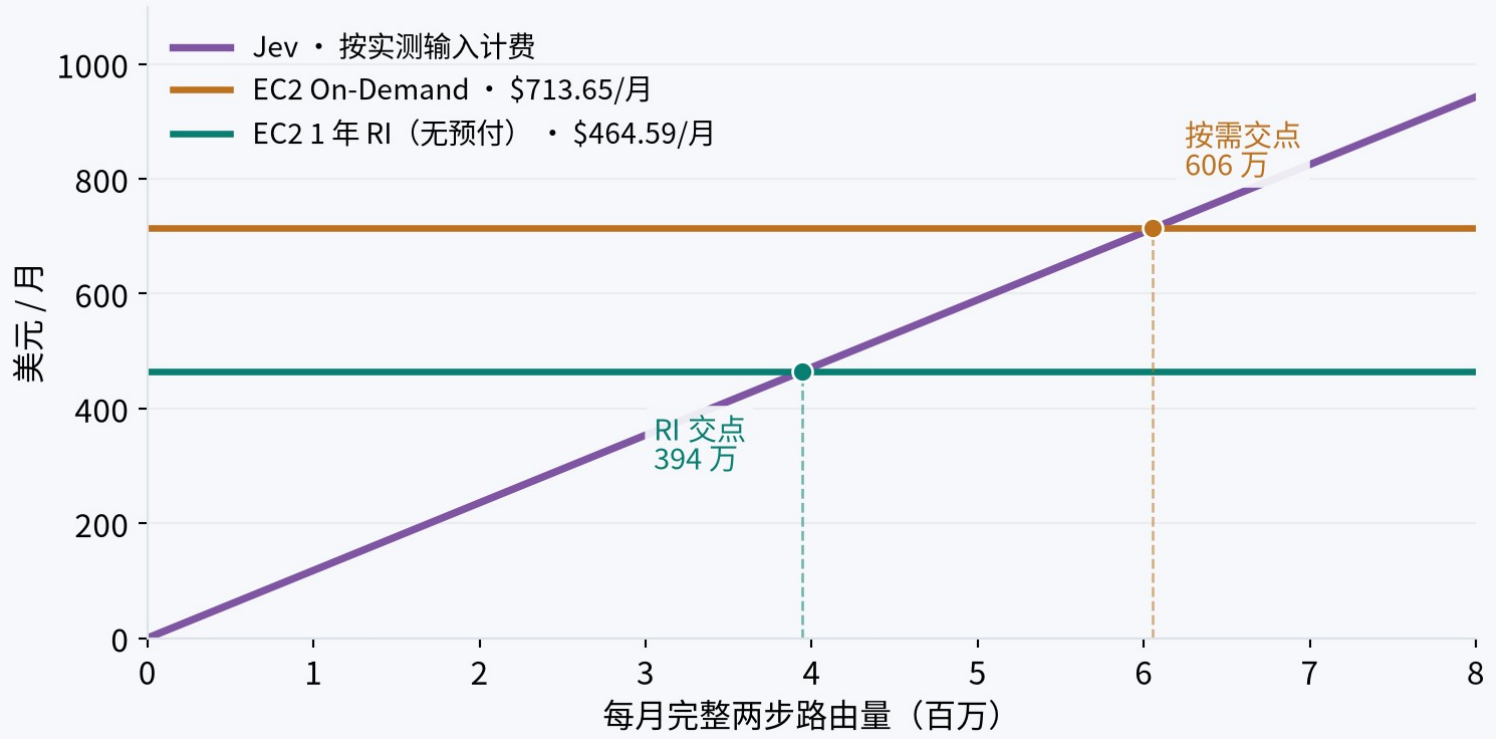
平均 656.95 输入 token / 次

Jev： $27.59 / 百万次

单台可承载时：低于 RI 交点， Jev 最省；两交点之间 RI 最省， Jev 仍比按需低；再增量，两种 EC2 都更低。

两步模型路由： 1 年 RI 的交点约 394 万条 / 月

一次完整路由包含“选流程 + 选型号”两次判断；输入更长， Jev 费用曲线也更陡。



1 年 RI 交点

约 394 万条 / 月

On-Demand 交点

约 606 万条 / 月

平均 2,805.75 输入 token / 条

Jev： $117.84 / 百万条

单台可承载时：低于 RI 交点， Jev 最省；两交点之间 RI 最省， Jev 仍比按需低；再增量，两种 EC2 都更低。

业务质量先过关，再在低延迟、自托管与按量之间选择

优化后支付： Decider 91.5 ms / 18/20； Jev 388.5 ms / 20/20； GPT 1271.9 ms / 20/20 。

Decider： 高频选择

优先：分类、工具选择、分流。

低单次延迟、可控自托管。
稳定流量再评估 1 年 RI 。
证据与完成判断需补强。

Jev： 证据与多步操作

优先：核验、文字浏览器操作。

低或波动流量，按量付费。
本批业务效果更好。
金额与路由硬约束仍复核。

GPT： 开放式复杂任务

适合：回复、代码、复杂异常。

本次支付参考一致 20/20 。
高频短选择要权衡延迟。
开放任务质量需单独实测。

打开演示，查看真实过程和原始记录

演示展示输入、原始选择、实际动作和结果；仓库保留验证脚本、截图与数据。

在线演示	https://d3i7ogfx5ml7dc.cloudfront.net
主项目	https://github.com/milan9527/StrandsDecider
vLLM 适配与公共 API	https://github.com/milan9527/StrandsDeciderVLLM
场景验证结果与截图	https://github.com/milan9527/StrandsDecider/blob/main/validation/README.md
Strands Decider 官方介绍	https://strandsagents.com/blog/introducing-strands-decider/
JevBench 评测结果与方法	https://benchmarkheaven.com/jev-models/api